

POLSKA A i B

Czyli analiza dualizmu społeczno-
gospodarczego w województwach Polski

Daniel Faltynowski

Dawid Kalinowski

Spis treści

.....	1
Opis problemu badawczego	3
Analiza wstępna	4
Interpretacja statystyk opisowych	8
Analiza korelacji	14
Analiza kanoniczna.....	20
Analiza siły związków liniowych	21
Interpretacja korelacji i ładunków kanonicznych	23
Testy istotności statystycznej	24
Analiza redundancji	25
Analiza głównych składowych.....	26
Wybór zmiennych do analizy	26
Wyniki działania algorytmu PCA	28
Wybór wymiarów	31
Metody porządkowania liniowego oraz nieliniowego	34
Wybór zmiennych do analizy	34
Charakter zmiennych	34
Metoda COPRAS.....	35
Ważona metoda Hellwiga.....	35
Ranking	36
Graf najbliższego sąsiada	39
Analiza skupień	41
Metoda Warda	41
Metoda k-średnich	42
Metoda Fuzzy c-średnich	46
Podsumowanie	49
Podsumowanie.....	50
Bibliografia.....	52

Opis problemu badawczego

Często potocznie i z pewną dozą ironii mówi się, że Polska dzieli się na dwa osobne kraje – tzw. Polskę „A” i „B”. W literaturze oraz debacie publicznej istnieją różnorodne interpretacje tego zjawiska. Część badaczy podchodzi do tematu w kontekście czysto ekonomicznym, wskazując, że jedna część kraju charakteryzuje się znacznie wyższym poziomem zamożności niż druga. Inni doszukują się przyczyn polaryzacji w asymetrii dostępu do edukacji, a jeszcze rzadziej – w strukturze przychodów z turystyki. Choć te partykularne ujęcia są niezwykle frapujące, w niniejszej pracy postawiono cel polegający na zweryfikowaniu tego problemu od strony ściśle statystycznej. Na podstawie realnych danych empirycznych podjęto próbę oceny, czy faktycznie polską przestrzeń regionalną można jednoznacznie podzielić na dwa odrębne podsystemy w ujęciu holistycznym.

Wprowadzeniem do tak zdefiniowanego problemu badawczego są współczesne analizy literaturowe, które osadzają dysproporcje terytorialne w kontekście globalnym. Wojciech Dziemianowicz, Jan Goliński i Jacek Szlachta w artykule *Dualizm ekonomiczny i megatrendy – przyczynek do dyskusji o rozwoju terytorialnym* wskazują, że współczesny dualizm ekonomiczny jest silnie determinowany przez tzw. megatrendy, czyli długotrwałe, globalne procesy o charakterze cywilizacyjnym, gospodarczym i społecznym, które nieodwracalnie zmieniają warunki funkcjonowania systemów przestrzennych. Z kolei Paweł Churski, Robert Perdał, Barbara Konecka-Szydłowska i Tomasz Herodowicz w artykule *Redefinicja czynników rozwoju regionalnego w świetle megatrendów społeczno-gospodarczych* podkreślają, że owe megatrendy wymuszają redefinicję tradycyjnych czynników rozwoju regionalnego, przesuując ciężar z zasobów materialnych na kapitał ludzki i innowacje. Ponieważ te nowoczesne, niematerialne kapitały koncentrują się głównie w metropoliach, mechanizmy globalne zamiast wyrównywać różnice, często petryfikują i pogłębiają struktury dualne, oddalając od siebie regiony silne od peryferyjnych.

W naszej analizie przyjrzymy się temu problemowi w kontekście identyfikacji ukrytych struktur oraz czynników determinujących zróżnicowanie przestrzenne. W pierwszym kroku spróbujemy dokonać redukcji wymiarowości pierwotnej przestrzeni informacyjnej do mniejszej liczby syntetycznych zmiennych losowych. Następnie skonstruujemy ranking jednostek terytorialnych przy użyciu miary syntetycznej, by ostatecznie dokonać obiektywnego podziału województw na jednorodne grupy. Aby zrealizować tak postawione cele, w pracy wykorzystano aparat metodologiczny, obejmujący analizę kanoniczną, analizę głównych składowych (PCA), metody porządkowania liniowego i nieliniowego oraz analizę skupień.

Analiza wstępna

Przed uruchomieniem wielowymiarowych algorytmów statystycznych, przeprowadzono wstępną weryfikację i selekcję zmiennych diagnostycznych w celu optymalnego scharakteryzowania specyfiki badanych jednostek terytorialnych. Głównym celem tego etapu było zidentyfikowanie wskaźników, które najsilniej różnicują polskie województwa i pozwalają na empiryczną ocenę zjawiska dualizmu społeczno-gospodarczego (koncepcji podziału na tzw. Polskę A i Polskę B).

Dane wykorzystane w badaniu zostały pozyskane z Banku Danych Lokalnych Głównego Urzędu Statystycznego (BDL GUS). Pierwotny zbiór obejmował 56 zmiennych stanowiących potencjalne predyktory rozwoju regionalnego w wymiarze demograficznym, gospodarczym, infrastrukturalnym oraz społecznym.

Kluczowym etapem przygotowania danych było przeprowadzenie relatywizacji zmiennych absolutnych (wielkości bezwzględnych) na wskaźniki względne (wskaźniki natężenia, takie jak liczba obiektów na 1 000 mieszkańców lub na 100 km^2). Pominięcie tej procedury doprowadziłoby do zniekształcenia wyników analizy przez tzw. efekt skali, w konsekwencji województwa o największej powierzchni i populacji (np. mazowieckie) byłyby automatycznie klasyfikowane jako najlepiej rozwinięte, natomiast jednostki najmniejsze (np. opolskie lub lubuskie) jako peryferyjne.

Dodatkowo podjęto próbę unifikacji rzędów wielkości analizowanych cech, dążąc do sytuacji, w której wartości empiryczne oscylują w umownym przedziale od 0 do 100. Pełny wykaz pozyskanych zmiennych diagnostycznych zamieszczono w Tabeli 1.1, natomiast kompletną macierz danych rzeczywistych przedstawiono w Tabeli 1.2.

Tabela 1.1 Lista cech rozważanych w analizie

GRUPA	ZMIENNA	OPIS
DEMOGRAFIA	x01	gęstość zaludnienie (os / km^2) - 2021 SP
DEMOGRAFIA	x02	wskaźnik urbanizacji 2021 - spis powszechny - ile osób % mieszka w miastach
DEMOGRAFIA	x03	emigranci - 2021 sp - odsetek emigrantów w % względem ludności województwa - czasowy pobyt za granica
DEMOGRAFIA	x04	LUDNOŚĆ PRZYBYŁA DO MIEJSCOWOŚCI AKTUALNEGO ZAMIESZKANIA W LATACH 2011-2021 Z INNEGO MIEJSCA W KRAJU
DEMOGRAFIA	x05	Przyrost naturalny - 2024 w % rok do roku
DEMOGRAFIA	x06	saldo migracji stałej w % rok do roku - 2024
EDUKACJA	x07	dzieci w przedszkolach i innych formach wychowania przedszkolnego na 1 tys. dzieci w wieku 3-5 lat 2024
EDUKACJA	x08	liczba studentów przypadających na jednego nauczyciela akademickiego - 2024
EDUKACJA	x09	studencki uczelni na 1,000 ludności - 2024
EDUKACJA	x10	zdawalność egzaminów maturalnych - 2024
GOSPODARKA	x11	pkb na osobę w 2023 w 1000 zł

GOSPODARKA	x12	podmioty wpisane do rejestru REGON na 1 tys. Ludności – 2024
GOSPODARKA	x13	dochody budżetów województw na 1 mieszkańca w roku 2024 w dziesiątkach złotych]
GOSPODARKA	x14	jednostki nowo zarejestrowane w rejestrze REGON w roku 2024 na 10 tys. Ludności
GOSPODARKA	x15	Przeciętne miesięczne wynagrodzenia brutto w 2024 w setkach zł
INSRASTRUKTURA TRANSPORTOWA	x16	liczba rowerów publicznych na 100,000 ludności 2024
INSRASTRUKTURA TRANSPORTOWA	x17	drogi dla rowerów na 1,000 km ² 2024
INSRASTRUKTURA TRANSPORTOWA	x18	kilometry dróg publicznych ogółem na 100 km ² - 2024
INSRASTRUKTURA TRANSPORTOWA	x19	kilometry dróg publicznych o nawierzchni twardej na 100 km ² - 2024
INSRASTRUKTURA TRANSPORTOWA	x20	(przystanki autobusowe (z trolejbusowymi) i tramwajowe, przystanki wspólne dla tramwajów i autobusów) na 100km ² w 2024
INSRASTRUKTURA TRANSPORTOWA	x21	długość linii komunikacji miejskiej na 100,000 mieszkańców 2024 w km
INSRASTRUKTURA TRANSPORTOWA	x22	przewozy pasażerskie na 1 mieszkańca 2024
INSRASTRUKTURA TRANSPORTOWA	x23	LINIE REGULARNEJ KOMUNIKACJI AUTOBUSOWEJ w km na 100km ² w 2024
INSRASTRUKTURA TRANSPORTOWA	x24	linie kolejowe ogółem na 1000 km ² w 2024
INSRASTRUKTURA TRANSPORTOWA	x25	samochody osobowe na 100 mieszkańców 2024
INSRASTRUKTURA TRANSPORTOWA	x26	wypadki drogowe na 100,000 mieszkańców 2024
INWESTYCJE	x27	nakłady inwestycyjne w przedsiębiorstwach na 1 mieszkańca w 2024 w setkach zł
INWESTYCJE	x28	WYDATKI BUDŻETÓW GMIN I MIAST NA PRAWACH POWIATU na 1 mieszkańca w 2024 w setkach zł
INWESTYCJE	x29	Wydatki budżetów gmin i miast na prawach powiatu na kulturę i ochronę dziedzictwa narodowego na 1 mieszkańca w 2024 w dziesiątkach złotych
INWESTYCJE	x30	Wydatki budżetów gmin i miast na prawach powiatu na oświatę 1 mieszkańca w 2024 w setkach zł
INWESTYCJE	x31	wydatki budżetów gmin i miast na prawach powiatu na Ochrona powietrza atmosferycznego i klimatu na 1 mieszkańca w 2024
INWESTYCJE	x32	wydatki inwestycyjne budżetów gmin i miast na prawach powiatu na 1 mieszkańca w 2024 w setkach zł
KULTURA	x33	biblioteki publiczne na 100,000 ludności w 2024
KULTURA	x34	pozycje księgozbioru bibliotek publicznych na 100 ludności
KULTURA	x35	średnia liczba godzin otwarcia biblioteki publicznej po godz. 16.00 w 2024 / powiększone 10-krotnie
KULTURA	x36	zajęcia prowadzone przez teatry i instytucje muzyczne, muzea oraz centra, domy, ośrodki kultury, kluby i świetlice na 10,000 ludności w 2024
KULTURA	x37	uczestnicy imprez (wydarzeń kulturalnych) organizowanych przez teatry i instytucje muzyczne, muzea, galerie sztuki, kina oraz centra, ośrodki kultury, domy kultury, kluby i świetlice na 1,000 ludności w 2024
OCHRONA ZDROWIA	x38	Lekarze pracujący bezpośrednio z pacjentem według województw w przeliczeniu na 10 tys. Mieszkańców – stan w dniu 31 grudnia 2023

OCHRONA ZDROWIA	x39	Lekarze dentyści pracujący bezpośrednio z pacjentem według województw – na 10 tys Mieszkańców – stan 31 grudnia 2023
OCHRONA ZDROWIA	x40	Pielęgniarki pracujące bezpośrednio z pacjentem według województw na 10 tys mieszkańców – 31 grudnia 2023
OCHRONA ZDROWIA	x41	Położne na 10,000 kobiet 31 grudnia 2023
OCHRONA ZDROWIA	x42	łóżka na oddziałach kardiologicznych na 100 tys. ludności
STAN MATERIALNY	x43	Stopa promil bezrobocia w grudniu 2024
STAN MATERIALNY	x44	BENEFICJENCI ŚRODOWISKOWEJ POMOCY SPOŁECZNEJ w promilach
TURYSTYKA	x45	miejsca noclegowe na 1000 ludności w 2024
TURYSTYKA	x46	udzielone noclegi ogółem styczeń-grudzień na 10 ludności w 2024
WARUNKI BYTOWE	x47	Liczba mieszkań na 100 mieszkańców w 2024 r
WARUNKI BYTOWE	x48	Odsetek ludności w obiektach zbiorowego zakwaterowania 2021 / powiększone 100-krotnie
WARUNKI BYTOWE	x49	liczba miejsc w domach studenckich w stosunku do liczby studentów 2024 - jaki odsetek studentów domy studenckie są w stanie pomieścić
WARUNKI BYTOWE	x50	studenci korzystający z domów studenckich w % ogółu studentów 2024
WARUNKI BYTOWE	x51	zasoby mieszkaniowe gmin komunalne 2024 na 10,000 mieszkańców
ZASOBY LUDZKIE	x52	WSPÓŁCZYNNIK AKTYWNOŚCI ZAWODOWEJ OSÓB W WIEKU 15-89 LAT w 4 kwartale 2024
ZASOBY LUDZKIE	x53	odsetek ludności w wieku produkcyjnym - 2021 sp
ZASOBY LUDZKIE	x54	odsetek ludności z wykształceniem wyższym. 2021 sp
ZASOBY LUDZKIE	x55	Współczynnik obciążenia demograficznego (liczba osób w wieku nieprodukcyjnym na 100 osób w wieku produkcyjnym - 2024
ZASOBY LUDZKIE	x56	Współczynnik obciążenia demograficznego (liczba osób w wieku nieprodukcyjnym na 100 osób w wieku produkcyjnym - 2024

Tabela 1.2 Wartości empiryczne

woj	x01	x02	x03	x04	x05	x06	x07	x08	x09	x10	x11	x12	x13	x14
DOLNOŚLĄSKIE	145,00	68,00	4,20	12,70	99,50	100,14	964,00	14,41	43,60	82,60	97,00	158,90	59,80	112,00
KUJAWSKO-POMORSKIE	112,00	58,50	3,94	10,80	99,51	99,91	903,00	13,48	28,60	82,80	72,84	115,90	45,11	85,00
LUBELSKIE	81,00	46,30	4,52	9,90	99,51	99,76	933,00	10,67	33,70	83,10	62,53	108,40	34,06	76,00
LUBUSKIE	71,00	64,60	4,36	10,90	99,51	99,92	955,00	9,47	12,70	83,10	72,44	138,60	47,21	102,00
ŁÓDZKIE	132,00	62,10	2,58	9,30	99,36	99,94	961,00	11,30	29,30	83,40	86,15	123,60	48,74	85,00
MAŁOPOLSKIE	226,00	48,00	4,18	10,70	99,82	100,17	954,00	11,92	45,70	87,00	80,98	145,60	54,10	109,00
MAZOWIECKIE	155,00	64,70	2,23	13,20	99,72	100,25	982,00	15,61	51,60	85,50	142,76	191,10	107,71	144,00
OPOLSKIE	101,00	53,20	5,79	9,90	99,43	99,88	980,00	13,97	23,30	81,00	72,96	123,20	46,99	71,00
PODKARPACKIE	117,00	41,30	6,42	8,80	99,69	99,88	940,00	14,72	22,10	84,10	64,99	103,80	47,34	73,00
PODLASKIE	57,00	60,90	5,96	9,20	99,61	99,89	946,00	11,09	26,20	82,40	70,08	109,30	39,73	76,00
POMORSKIE	129,00	63,10	3,78	13,80	99,75	100,23	921,00	15,09	40,30	83,10	86,64	156,70	60,13	121,00
ŚLĄSKIE	355,00	76,10	3,14	9,60	99,40	99,93	974,00	14,22	28,20	84,30	93,59	127,10	54,10	82,00
ŚWIĘTOKRZYSKIE	101,00	45,00	4,52	8,80	99,33	99,77	934,00	12,97	16,60	85,80	67,85	114,00	38,98	76,00
WARMIŃSKO-MAZURSKIE	57,00	59,30	5,31	10,70	99,53	99,82	903,00	11,24	17,30	84,40	64,08	111,30	33,23	78,00
WIELKOPOLSKIE	117,00	53,80	2,59	13,40	99,72	100,06	966,00	12,53	32,40	83,00	95,10	149,10	59,65	105,00
ZACHODNIOPOMORSKIE	72,00	68,40	4,61	10,80	99,44	99,99	932,00	10,73	22,90	82,70	74,40	157,20	49,03	104,00

woj	x15	x16	x17	x18	x19	x20	x21	x22	x23	x24	x25	x26	x27	x28
DOLNOŚLĄSKIE	88,67	94,00	72,71	123,49	105,12	63,36	170,00	78,12	137,17	9,20	62,17	65,40	76,51	95,19
KUJAWSKO-POMORSKIE	77,11	42,00	96,12	154,19	114,35	68,51	110,00	81,79	171,27	6,70	58,98	39,48	53,51	88,91
LUBELSKIE	77,71	44,00	52,12	147,57	97,64	53,02	140,00	60,22	93,44	4,40	61,80	42,02	37,06	84,59
LUBUSKIE	78,87	42,00	65,69	106,49	63,69	27,24	190,00	45,36	108,49	6,50	66,35	47,38	60,13	89,23
ŁÓDZKIE	80,96	96,00	69,95	139,87	117,98	72,67	150,00	86,44	156,61	6,00	61,91	94,56	52,86	90,46
MAŁOPOLSKIE	88,19	39,00	89,27	209,70	174,25	116,15	170,00	118,01	58,28	7,10	56,93	72,14	49,45	87,23
MAZOWIECKIE	100,19	81,00	90,30	158,41	117,74	70,27	110,00	153,68	197,37	5,00	67,39	52,01	136,87	108,43
OPOLSKIE	79,58	8,00	73,01	110,60	91,76	50,85	90,00	29,91	147,10	8,30	62,15	52,74	71,97	86,18
PODKARPACKIE	75,15	7,00	49,10	115,31	96,06	61,68	150,00	22,51	164,32	5,50	57,54	48,99	45,57	85,54
PODLASKIE	78,50	82,00	45,60	135,57	76,14	36,58	110,00	56,60	150,37	3,80	54,76	30,49	37,02	93,30
POMORSKIE	86,20	179,00	93,04	114,60	84,50	59,10	140,00	124,78	159,27	6,40	58,38	71,45	74,56	92,58
ŚLĄSKIE	85,38	176,00	132,32	198,98	177,07	121,92	320,00	79,68	73,83	15,30	58,37	41,34	76,15	89,87
ŚWIĘTOKRZYSKIE	76,64	48,00	46,02	146,90	126,91	119,96	130,00	41,18	131,96	6,20	57,35	56,91	39,08	82,40
WARMIŃSKO-MAZURSKIE	75,29	0,00	39,80	92,27	61,23	32,90	110,00	47,76	85,36	4,60	56,55	55,82	38,62	83,76
WIELKOPOLSKIE	77,59	25,00	102,67	138,03	104,93	58,06	190,00	90,44	117,66	6,40	65,63	70,79	68,94	86,04
ZACHODNIOPOMORSKIE	80,27	87,00	59,18	81,59	62,03	33,00	140,00	117,13	129,26	5,40	57,70	45,78	53,31	90,44

woj	x29	x30	x31	x32	x33	x34	x35	x36	x37	x38	x39	x40	x41	x42
DOLNOŚLĄSKIE	39,98	31,48	17,77	16,38	20,00	28,33	45,00	40,00	166,50	39,20	10,70	55,70	12,20	18,30
KUJAWSKO-POMORSKIE	31,08	31,01	22,59	15,60	19,00	34,31	34,00	40,00	128,50	31,50	6,40	55,10	13,70	29,90
LUBELSKIE	31,85	31,94	22,44	18,19	28,00	32,90	29,00	20,00	158,90	38,90	10,60	68,40	16,70	22,70
LUBUSKIE	33,06	31,10	8,80	17,54	24,00	39,23	44,00	30,00	247,00	25,00	7,90	47,00	10,70	13,90
ŁÓDZKIE	31,97	29,41	20,72	17,54	19,00	33,13	49,00	30,00	102,70	43,10	11,60	55,50	16,70	27,00
MAŁOPOLSKIE	34,69	33,23	32,51	14,25	21,00	33,37	46,00	70,00	208,10	37,10	9,80	57,10	14,80	21,60
MAZOWIECKIE	39,39	38,20	18,49	17,14	17,00	31,92	57,00	70,00	168,00	52,20	12,20	63,60	16,30	27,90
OPOLSKIE	33,79	30,40	14,94	14,17	32,00	39,35	50,00	30,00	95,80	25,70	7,20	55,40	12,90	27,20
PODKARPACKIE	30,73	31,22	19,25	18,85	32,00	41,32	38,00	40,00	157,60	28,60	8,20	65,00	16,80	25,10
PODLASKIE	33,69	33,55	22,95	22,20	20,00	43,11	37,00	40,00	155,70	41,40	11,10	63,20	16,80	24,50
POMORSKIE	29,99	33,62	10,86	14,00	13,00	20,88	54,00	40,00	158,30	36,80	10,10	45,80	12,00	17,40
ŚLĄSKIE	27,01	34,02	24,06	12,80	17,00	34,79	55,00	40,00	153,10	38,30	9,30	60,90	14,20	24,60
ŚWIĘTOKRZYSKIE	31,06	27,68	22,42	15,68	22,00	36,57	32,00	30,00	146,10	32,20	8,70	70,20	16,00	23,60
WARMIŃSKO-MAZURSKIE	33,11	28,73	11,33	15,76	21,00	28,39	45,00	30,00	241,20	26,40	7,10	53,00	12,20	17,30
WIELKOPOLSKIE	30,48	33,45	21,10	15,58	18,00	32,79	41,00	30,00	120,50	30,70	8,80	48,00	15,40	19,10
ZACHODNIOPOMORSKIE	35,90	29,02	9,80	16,56	21,00	36,33	60,00	30,00	175,50	34,00	10,70	48,10	12,60	15,30

woj	x43	x44	x45	x46	x47	x48	x49	x50	x51	x52	x53	x54	x55	x56
DOLNOŚLĄSKIE	46,00	23,00	29,87	39,16	46,30	84,34	6,85	4,70	32,02	60,00	59,50	25,30	71,40	71,40
KUJAWSKO-POMORSKIE	73,00	46,00	16,53	23,74	41,30	68,07	7,99	6,70	19,25	59,20	59,30	20,30	72,10	72,10
LUBELSKIE	74,00	35,00	13,52	11,89	41,30	71,66	10,93	6,80	9,81	56,70	58,60	23,40	73,60	73,60
LUBUSKIE	45,00	34,00	18,44	15,09	42,50	78,36	12,76	9,00	23,43	56,60	59,00	20,00	72,30	72,30
ŁÓDZKIE	54,00	31,00	9,95	10,91	46,10	85,47	10,78	7,80	29,00	56,10	57,90	23,00	76,00	76,00
MAŁOPOLSKIE	41,00	27,00	30,18	45,21	39,80	94,97	11,59	9,70	8,77	59,30	60,20	25,60	68,90	68,90
MAZOWIECKIE	40,00	25,00	13,09	20,22	46,48	95,62	5,82	4,60	21,83	63,30	59,10	32,40	70,80	70,80
OPOLSKIE	59,00	29,00	8,46	8,27	39,80	102,20	11,91	10,60	20,97	59,50	60,30	20,70	70,50	70,50
PODKARPACKIE	87,00	40,00	16,74	17,27	35,30	62,72	9,15	7,20	6,66	52,70	60,10	22,20	69,80	69,80
PODLASKIE	70,00	43,00	12,73	11,27	42,50	61,94	11,87	6,10	11,46	56,10	59,60	23,80	72,10	72,10
POMORSKIE	46,00	33,00	49,07	46,25	42,50	87,36	8,28	6,30	19,89	60,10	59,60	25,40	70,30	70,30
ŚLĄSKIE	36,00	22,00	11,24	14,31	44,50	72,48	7,74	6,00	34,20	55,90	58,90	22,80	73,60	73,60
ŚWIĘTOKRZYSKIE	76,00	43,00	16,58	17,58	39,80	76,83	11,46	6,20	9,08	55,50	58,30	22,80	75,60	75,60
WARMIŃSKO-MAZURSKIE	84,00	52,00	30,84	25,72	41,30	69,40	9,00	8,60	17,72	54,30	59,90	20,20	70,90	70,90
WIELKOPOLSKIE	29,00	30,00	11,66	11,06	39,80	69,20	8,16	4,30	13,39	59,90	59,60	23,10	70,50	70,50
ZACHODNIOPOMORSKIE	68,00	33,00	94,50	101,57	44,50	105,82	18,28	12,30	26,18	58,10	59,20	22,60	72,70	72,70

Interpretacja statystyk opisowych

W tabeli 1.3 przedstawiono najważniejsze statystyki opisowe badanych zmiennych. Choć klasyczne miary, takie jak średnia arytmetyczna czy mediana, pozwalają na ogólne zorientowanie się w skali zjawisk, to z punktu widzenia dalszych etapów analizy wielowymiarowej kluczowe znaczenie ma ocena zmienności oraz asymetrii rozkładów. To właśnie te dwie cechy decydują o tym, czy dany wskaźnik wnosi do badania realną wartość informacyjną, czy też powinien zostać z niego wykluczony.

Tabela 1.3 Statystyki opisowe wraz z interpretacją

Zmienna	N	Średnia	Mediana	Min	Max	Odch_Std	Skosnosc	Kurtoza	Wsp_Zm_Proc	Gini	Klasa_Asymetrii	Klasa_Zmienności
x01	16	126.75	114.5	57	355	74.29	2.18	5.72	58.61	0.27	silna prawostronna	duża zmienność
x02	16	58.33	60.1	41.3	76.1	9.66	-0.18	-0.6	16.57	0.09	staba/umiarkowana	mała zmienność
x03	16	4.26	4.28	2.23	6.42	1.23	0.03	-0.58	28.8	0.16	staba/umiarkowana	umiarkowana zmienność
x04	16	10.78	10.7	8.8	13.8	1.65	0.69	-0.74	15.34	0.08	staba/umiarkowana	mała zmienność
x05	16	99.55	99.51	99.33	99.82	0.15	0.33	-1.07	0.15	0	staba/umiarkowana	bardzo mała zmienność
x06	16	99.97	99.93	99.76	100.25	0.16	0.59	-0.73	0.16	0	staba/umiarkowana	bardzo mała zmienność
x07	16	946.75	950	903	982	24.75	-0.38	-0.66	2.61	0.01	staba/umiarkowana	bardzo mała zmienność
x08	16	12.71	12.75	9.47	15.61	1.85	-0.06	-1.23	14.57	0.08	staba/umiarkowana	mała zmienność
x09	16	29.66	28.4	12.7	51.6	11.07	0.49	-0.45	37.34	0.2	staba/umiarkowana	umiarkowana zmienność
x10	16	83.64	83.1	81	87	1.49	0.73	0.68	1.78	0.01	staba/umiarkowana	bardzo mała zmienność
x11	16	81.52	73.68	62.53	142.76	19.84	2.09	5.64	24.34	0.12	silna prawostronna	mała zmienność
x12	16	133.36	125.35	103.8	191.1	24.5	0.83	0.22	18.37	0.1	staba/umiarkowana	mała zmienność
x13	16	51.62	48.04	33.23	107.71	17.18	2.44	7.93	33.28	0.15	silna prawostronna	umiarkowana zmienność
x14	16	93.69	85	71	144	20.92	0.97	0.45	22.33	0.12	staba/umiarkowana	mała zmienność
x15	16	81.64	79.23	75.15	100.19	6.61	1.64	2.99	8.09	0.04	silna prawostronna	bardzo mała zmienność
x16	16	65.62	46	0	179	53.57	1.02	0.66	81.63	0.42	staba/umiarkowana	bardzo duża zmienność
x17	16	73.56	71.33	39.8	132.32	25.48	0.67	0.14	34.64	0.19	staba/umiarkowana	umiarkowana zmienność
x18	16	135.85	136.8	81.59	209.7	34.58	0.68	0.46	25.45	0.14	staba/umiarkowana	umiarkowana zmienność
x19	16	104.46	101.29	61.23	177.07	34.56	0.89	0.63	33.08	0.17	staba/umiarkowana	umiarkowana zmienność
x20	16	65.33	60.39	27.24	121.92	30.22	0.89	-0.02	46.26	0.24	staba/umiarkowana	umiarkowana zmienność
x21	16	151.25	140	90	320	53.9	2.15	6.23	35.64	0.17	silna prawostronna	umiarkowana zmienność
x22	16	77.1	78.9	22.51	153.68	37.22	0.46	-0.46	48.27	0.26	staba/umiarkowana	umiarkowana zmienność
x23	16	130.11	134.56	58.28	197.37	38.29	-0.31	-0.52	29.43	0.16	staba/umiarkowana	umiarkowana zmienność
x24	16	6.68	6.3	3.8	15.3	2.68	2.4	7.26	40.2	0.18	silna prawostronna	umiarkowana zmienność
x25	16	60.25	58.68	54.76	67.39	3.79	0.62	-0.67	6.29	0.03	staba/umiarkowana	bardzo mała zmienność
x26	16	55.46	52.37	30.49	94.56	16.08	0.85	0.89	28.99	0.15	staba/umiarkowana	umiarkowana zmienność
x27	16	60.73	53.41	37.02	136.87	24.87	1.98	5.4	40.95	0.2	silna prawostronna	umiarkowana zmienność
x28	16	89.64	89.07	82.4	108.43	6.15	1.96	5.41	6.87	0.03	silna prawostronna	bardzo mała zmienność
x29	16	32.99	32.52	27.01	39.98	3.35	0.71	0.73	10.15	0.05	staba/umiarkowana	mała zmienność
x30	16	31.75	31.35	27.68	38.2	2.59	0.74	1.26	8.15	0.04	staba/umiarkowana	bardzo mała zmienność
x31	16	18.75	19.98	8.8	32.51	6.32	0.1	0.1	33.69	0.18	staba/umiarkowana	umiarkowana zmienność
x32	16	16.39	16.07	12.8	22.2	2.26	0.91	1.78	13.79	0.07	staba/umiarkowana	mała zmienność
x33	16	21.5	20.5	13	32	5.24	0.91	0.57	24.38	0.13	staba/umiarkowana	mała zmienność
x34	16	34.17	33.84	20.88	43.11	5.47	-0.64	1.18	16.01	0.08	staba/umiarkowana	mała zmienność
x35	16	44.75	45	29	60	9.19	-0.06	-0.87	20.54	0.11	staba/umiarkowana	mała zmienność
x36	16	38.12	35	20	70	13.77	1.61	2.4	36.12	0.17	silna prawostronna	umiarkowana zmienność
x37	16	161.47	157.95	95.8	247	42.44	0.64	0.39	26.28	0.14	staba/umiarkowana	umiarkowana zmienność
x38	16	35.07	35.4	25	52.2	7.28	0.6	0.5	20.76	0.11	staba/umiarkowana	mała zmienność
x39	16	9.4	9.55	6.4	12.2	1.73	-0.17	-1	18.37	0.1	staba/umiarkowana	mała zmienność
x40	16	57	55.6	45.8	70.2	7.65	0.16	-0.98	13.42	0.07	staba/umiarkowana	mała zmienność
x41	16	14.38	14.5	10.7	16.8	2.07	-0.23	-1.43	14.43	0.08	staba/umiarkowana	mała zmienność
x42	16	22.21	23.15	13.9	29.9	4.83	-0.2	-1.09	21.75	0.12	staba/umiarkowana	mała zmienność
x43	16	58	56.5	29	87	18.22	0.08	-1.34	31.41	0.17	staba/umiarkowana	umiarkowana zmienność
x44	16	34.12	33	22	52	8.62	0.53	-0.4	25.25	0.14	staba/umiarkowana	umiarkowana zmienność
x45	16	23.96	16.56	8.46	94.5	21.64	2.65	7.82	90.3	0.38	silna prawostronna	bardzo duża zmienność
x46	16	26.22	17.42	8.27	101.57	23.5	2.47	7.04	89.64	0.39	silna prawostronna	bardzo duża zmienność
x47	16	42.11	41.9	35.3	46.48	2.99	-0.34	0.35	7.1	0.04	staba/umiarkowana	bardzo mała zmienność
x48	16	80.4	77.59	61.94	105.82	13.81	0.47	-0.91	17.18	0.09	staba/umiarkowana	mała zmienność
x49	16	10.16	9.96	5.82	18.28	2.99	1.17	2.54	29.38	0.15	staba/umiarkowana	umiarkowana zmienność
x50	16	7.31	6.75	4.3	12.3	2.24	0.74	0.12	30.7	0.16	staba/umiarkowana	umiarkowana zmienność
x51	16	18.98	19.57	6.66	34.2	8.62	0.23	-0.99	45.41	0.25	staba/umiarkowana	umiarkowana zmienność
x52	16	57.71	57.4	52.7	63.3	2.68	0.13	-0.02	4.64	0.02	staba/umiarkowana	bardzo mała zmienność
x53	16	59.32	59.4	57.9	60.3	0.68	-0.5	-0.15	1.14	0.01	staba/umiarkowana	bardzo mała zmienność
x54	16	23.35	22.9	20	32.4	3	1.83	5.02	12.86	0.06	silna prawostronna	mała zmienność
x55	16	71.94	71.75	68.9	76	1.99	0.71	0.03	2.77	0.01	staba/umiarkowana	bardzo mała zmienność
x56	16	71.94	71.75	68.9	76	1.99	0.71	0.03	2.77	0.01	staba/umiarkowana	bardzo mała zmienność

W celu interpretacji kierunku i siły asymetrii rozkładu poszczególnych zmiennych, przyjęto następujące kryteria formalne:


- Słaba / umiarkowana asymetria ($|skosnosc| \leq 1.2$): Oznacza, że rozkład danych jest w miarę symetryczny. Wartości badanych cech rozkładają się w miarę równomiernie wokół średniej, co oznacza stabilną sytuację w większości województw, choć sporadycznie mogą pojawić się pojedyncze wartości nietypowe.
- Silna skośność prawostronna ($skosnosc > 1.2$): Oznacza, że większość województw cechuje się zbliżonymi, niższymi wartościami. Tam koncentrują się dane. Natomiast ogólna średnia dla kraju jest zawyżana przez nieliczne województwa osiągające skrajnie wysokie, nietypowe wyniki
- Silna skośność lewostronna ($skosnosc < -1.2$): Sytuacja odwrotna – punkt koncentracji danych znajduje się powyżej średniej. Zdecydowana większość regionów osiąga wysokie, zbliżone wyniki, natomiast ogólną średnią dla Polski zaniża zaledwie kilka województw o skrajnie niskich wartościach

W kontekście analizowanego zbioru danych, zdecydowana większość badanych zmiennych cechuje się słabą/umiarkowaną asymetrią. Świadczy to o tym, że pod względem większości wskaźników społeczno-gospodarczych polskie województwa nie wykazują drastycznych, punktowych anomalii, a przejścia między poziomami rozwoju są w miarę płynne. Istnieją jednak wyraźne wyjątki od tej reguły, które odstaniają dysproporcje w konkretnych obszarach.

Tabela 1.4 Opis zmiennych, dla których stwierdzono silną prawostronną asymetrię

DEMOGRAFIA	x01	gęstość zaludnienie (os / km2) - 2021 SP
GOSPODARKA	x11	pkb na osobę w 2023 w 1000 zł
GOSPODARKA	x13	dochody budżetów województw na 1 mieszkańca w roku 2024 w dziesiątkach złotych
GOSPODARKA	x15	Przeciętne miesięczne wynagrodzenia brutto w 2024 w setkach zł
INSRASTRUKTURA TRANSPORTOWA	x21	długość linii komunikacji miejskiej na 100,000 mieszkańców 2024 w km
INSRASTRUKTURA TRANSPORTOWA	x24	linie kolejowe ogółem na 1000 km2 w 2024
INWESTYCJE	x27	nakłady inwestycyjne w przedsiębiorstwach na 1 mieszkańca w 2024 w setkach zł
INWESTYCJE	x28	WYDATKI BUDŻETÓW GMIN I MIAST NA PRAWACH POWIATU na 1 mieszkańca w 2024 w setkach zł
KULTURA	x36	zajęcia prowadzone przez teatry i instytucje muzyczne, muzea oraz centra, domy, ośrodki kultury, kluby i świetlice na 10,000 ludności w 2024
TURYSTYKA	x45	miejsca noclegowe na 1000 ludności w 2024
TURYSTYKA	x46	udzielone noclegi ogółem styczeń-grudzień na 10 ludności w 2024
ZASOBY LUDZKIE	x54	odsetek ludności z wykształceniem wyższym. 2021 sp

Silna asymetria prawostronna (Skośność > 1.2)



Rysunek 1.1 Histogramy zmiennych, dla których stwierdzono silną asymetrię prawostronną

Analiza histogramów na rysunku 1.1 wskazuje, że dla większości zmiennych wartości koncentrują się w dolnych przedziałach ich klasycznych obszarów zmienności. Wyraźnie widocznym zjawiskiem jest jednak występowanie pojedynczych, silnych obserwacji nietypowych dla każdej z badanych cech. W związku z tym w kolejnym kroku zidentyfikowano województwa generujące te anomalie, co pozwoliło wskazać jednoznacznych liderów poszczególnych wymiarów rozwoju.

Zestawienie województw osiągających maksymalne wartości dla poszczególnych zmiennych przedstawiono w tabeli 1.5. Zgodnie z przewidywaniami, w zestawieniu dominuje województwo mazowieckie, które wyznacza górną granicę wielowymiarowego rozwoju kraju. Region ten notuje najwyższe wskaźniki w kluczowych obszarach gospodarczych i społecznych, takich jak: PKB, dochody budżetów regionalnych, przeciętne wynagrodzenia oraz nakłady inwestycyjne. Mazowsze jest również liderem pod względem poziomu wykształcenia mieszkańców oraz aktywności instytucji kulturalnych. Co istotne z punktu widzenia metodologicznego, dominacja ta jest wyraźna pomimo wcześniejszego przeliczenia danych per capita oraz ich przeskalowania. Dowodzi to, że region stołeczny stanowi silną, autonomiczną obserwację odstającą, która w unikalny sposób różnicuje strukturę gospodarczą Polski.

Województwo śląskie dystansuje pozostałe regiony pod względem gęstości zaludnienia oraz rozwoju infrastruktury transportowej, zarówno drogowej, jak i kolejowej. Wynik ten

w pełni odzwierciedla specyfikę policentrycznej konurbacji górnośląskiej, charakteryzującej się unikalną w skali kraju siecią powiązanych ze sobą miast.

Województwo zachodniopomorskie okazuje się bezkonkurencyjne w wymiarze turystycznym, osiągając najwyższy wskaźnik liczby udzielonych noclegów. Potwierdza to silną specjalizację funkcjonalną tego regionu jako głównego bieguna turystyki w Polsce.

Tabela 1.5 Zmienne z silną asymetrią prawostronną wraz z województwami, dla których wartość zmiennej jest największa

ZMIENNA	NAJWIĘKSZA WARTOŚĆ	OPIS
x01	ŚLĄSKIE	gęstość zaludnienie (os / km ²) - 2021 SP
x11	MAZOWIECKIE	pkb na osobę w 2023 w 1000 zł
x13	MAZOWIECKIE	dochody budżetów województw na 1 mieszkańca w roku 2024 w dziesiątkach złotych]
x15	MAZOWIECKIE	Przeciętne miesięczne wynagrodzenia brutto w 2024 w setkach zł
x21	ŚLĄSKIE	długość linii komunikacji miejskiej na 100,000 mieszkańców 2024 w km
x24	ŚLĄSKIE	linie kolejowe ogółem na 1000 km ² w 2024
x27	MAZOWIECKIE	nakłady inwestycyjne w przedsiębiorstwach na 1 mieszkańca w 2024 w setkach zł
x28	MAZOWIECKIE	WYDATKI BUDŻETÓW GMIN I MIAST NA PRAWACH POWIATU na 1 mieszkańca w 2024 w setkach zł
x36	MAŁOPOLSKIE	zajęcia prowadzone przez teatry i instytucje muzyczne, muzea oraz centra, domy, ośrodki kultury, kluby i świetlice na 10,000 ludności w 2024
x45	ZACHODNIOPOMORSKIE	miejsca noclegowe na 1000 ludności w 2024
x46	ZACHODNIOPOMORSKIE	udzielone noclegi ogółem styczeń-grudzień na 10 ludności w 2024
x54	MAZOWIECKIE	odsetek ludności z wykształceniem wyższym. 2021 sp

Biorąc powyższe pod uwagę, zidentyfikowane anomalie mają charakter w pełni merytoryczny i wynikają ze specyfiki ekonomiczno-geograficznej badanych regionów. Nie stanowią one błędów pomiarowych ani rejestracyjnych, w związku z czym podjęto decyzję o pozostawieniu ich w zbiorze danych. Ich eliminacja pozbawiłaby model kluczowych informacji o rzeczywistych dysproporcjach regionalnych.


Równoległe z badaniem asymetrii, kluczowym elementem analizy wstępnej była ocena poziomu zróżnicowania zmiennych za pomocą klasycznego współczynnika zmienności (v). Pozwoliło to określić siłę, z jaką poszczególne wskaźniki różnicują badane województwa. Na potrzeby raportu przyjęto pięciostopniową klasyfikację poziomu zmienności, określoną następującymi kryteriami formalnymi:

- Zmienność bardzo mała ($v < 10\%$): Cechy z tego przedziału charakteryzują się niemal identycznym poziomem we wszystkich województwach. Ze względu na brak zdolności dyskryminacyjnych (nie różnicują obiektów), zmienne takie


powinny być potencjalnie eliminowane z dalszego postępowania taksonomicznego.

- Zmienność mała ($10\% \leq v < 25\%$): Wskazuje na stabilny i relatywnie wyrównany poziom zjawiska w skali kraju, z nieznacznymi tylko odchyleniami między regionami.
- Zmienność umiarkowana ($25\% \leq v < 50\%$): To najbardziej pożądany statystycznie przedział. Sygnalizuje on istnienie wyraźnych, ale naturalnych dysproporcji regionalnych, stanowiąc doskonałą bazę dla metod porządkowania liniowego i analizy skupień.
- Zmienność duża ($50\% \leq v < 75\%$): Świadczy o głębokim rozwarstwieniu między województwami. Wartości tych zmiennych w poszczególnych regionach mogą różnić się nawet kilkukrotnie.
- Zmienność bardzo duża ($v \geq 75\%$): Oznacza występowanie ekstremalnych dysproporcji. Tak wysoki współczynnik jest zazwyczaj generowany przez obecność opisanych wcześniej silnych obserwacji nietypowych, którzy całkowicie dystansują resztę kraju.

Zmienne o dużej zmienności (Wsp. Zm. > 50%)



Rysunek 2 Histogram zmiennych o dużej zmienności



Rysunek 1.3 Wizualizacja przedstawiająca zmienność

Zmienne wykazujące się największą zmiennością wymienione zostały w tabeli 1.6.


Tabela 1.6 Zmienne cechujące się dużą zmiennością powyżej 50%

DEMOGRAFIA	x01	gęstość zaludnienie (os / km2) - 2021 SP
INSRASTRUKTURA TRANSPORTOWA	x16	liczba rowerów publicznych na 100,000 ludności w 2024
TURYSTYKA	x45	miejsca noclegowe na 1000 ludności w 2024
TURYSTYKA	x46	udzielone noclegi ogółem styczeń-grudzień na 10 ludności w 2024

Wszystkie zmienne zaliczone do grupy „turystyka” charakteryzują się dużą zmiennością, co dowodzi, że pod względem atrakcyjności i infrastruktury turystycznej Polska jest krajem wyjątkowo zróżnicowanym regionalnie. Niekwestionowanym liderem w tym obszarze okazuje się województwo zachodniopomorskie, które ze względu na swój nadmorski charakter skupia największy ruch turystyczny.

Pewnym zaskoczeniem na pierwszy rzut oka może być fakt, że województwo mazowieckie – mimo obecności stolicy państwa i generowania ogromnego ruchu biznesowego oraz kulturalnego – nie notuje wysokich wartości w tej grupie zmiennych. Zjawisko to ma jednak głębokie uzasadnienie strukturalne. Ponieważ wszystkie analizowane wskaźniki zostały przeliczone per capita, w odniesieniu do liczby stałych mieszkańców, potężna baza demograficzna Mazowsza naturalnie „wygasza” i relatywizuje surowe dane dotyczące liczby turystów czy miejsc noclegowych. Ponadto turystyka na Mazowszu ma charakter głównie krótkookresowy, biznesowy i weekendowy, podczas gdy regiony typowo wypoczynkowe, takie jak pas nadmorski, generują znacznie

dłuższe i bardziej masowe pobyty, co bezpośrednio przekłada się na wyższe wartości wskaźników natężenia.




Rysunek 1.4 Wykres syntetyczny, podsumowujący dotychczasowe rozważania

Na rysunku 1.4 przedstawiono wykres syntetyczny, który zestawia wszystkie analizowane zmienne w ramach jednej przestrzeni badawczej. Wyraźnie widać, że podczas gdy większość cech charakteryzuje się stabilnymi i umiarkowanymi parametrami, część wskaźników drastycznie od nich odstaje. Oznacza to, że w badanym zbiorze mamy zarówno zmienne będące silnymi determinantami nierówności społeczno-gospodarczych, jak i takie, które te różnice wygładzają. Z punktu widzenia metodologicznego jest to sytuacja korzystna, ponieważ wysoka wewnętrzna różnorodność danych potwierdza, że zbiór jest kompletny i pozwala na efektywne zastosowanie szerokiej gamy zaawansowanych metod analizy wielowymiarowej w kolejnych rozdziałach pracy.


Analiza korelacji

Na rysunku 1.5 przedstawiono pełną macierz korelacji liniowych między wszystkimi cechami wchodzącymi w skład analizowanego zbioru danych. Wizualizacja ta ujawnia wyraźną tendencję do tworzenia się silnie powiązanych bloków tematycznych. Wzajemną, ścisłą zależnością charakteryzują się przede wszystkim zmienne z przedziału od x_{11} do x_{15} , reprezentujące sferę gospodarki oraz wskaźniki od x_{27} do x_{32} , opisujące nakłady i wydatki inwestycyjne. Takie ustrukturyzowanie przestrzeni informacyjnej stanowi kluczowy punkt wyjścia oraz merytoryczne uzasadnienie dla kolejnych kroków

badawczych, w tym redukcji wymiarowości oraz analizy kanonicznej. W celu pogłębienia tej obserwacji wyizolowano 25 najsilniejszych współczynników korelacji (dodatnich oraz ujemnych), które szczegółowo zilustrowano na rysunkach 1.6 oraz 1.7.




Rysunek 1.5 Mapa ciepła przedstawiająca korelacje między zmiennymi w zbiorze



Rysunek 1.6 Wykres przedstawiający 25 największych korelacji

Top 25 najsilniejszych korelacji - wykresy rozrzutu

Z linią trendu (lm); wolne skale dla każdej pary



Rysunek 1.7 Wykres rozrzutu przedstawiający relacje między 25 najbardziej skorelowanymi zmiennymi

Tabela 1.7 Zestawienie opisów 25 najbardziej skorelowanych ze sobą zmiennych

LABEL	OPIS CECHY 1	OPIS CECHY 2
x45 - x46	miejsca noclegowe na 1000 ludności w 2024	udzielone noclegi ogółem styczeń-grudzień na 10 ludności w 2024
x11 - x13	pkb na osobę w 2023 w 1000 zł	dochody budżetów województw na 1 mieszkańca w roku 2024 w dziesiątkach złotych

LABEL	OPIS CECHY 1	OPIS CECHY 2
x12 - x14	podmioty wpisane do rejestru REGON na 1 tys. Ludności – 2024	jednostki nowo zarejestrowane w rejestrze REGON w roku 2024 na 10 tys. Ludności
x13 - x27	dochody budżetów województw na 1 mieszkańca w roku 2024 w dziesiątkach złotych	nakłady inwestycyjne w przedsiębiorstwach na 1 mieszkańca w 2024 w setkach zł
x11 - x27	pkb na osobę w 2023 w 1000 zł	nakłady inwestycyjne w przedsiębiorstwach na 1 mieszkańca w 2024 w setkach zł
x19 - x20	kilometry dróg publicznych o nawierzchni twardej na 100 km ² - 2024	(przystanki autobusowe (z trolejbusowymi) i tramwajowe, przystanki wspólne dla tramwajów i autobusów) na 100km ² w 2024
x18 - x19	kilometry dróg publicznych ogółem na 100 km ² - 2024	kilometry dróg publicznych o nawierzchni twardej na 100 km ² - 2024
x53 - x56	odsetek ludności w wieku produkcyjnym - 2021 sp	Współczynnik obciążenia demograficznego (liczba osób w wieku nieprodukcyjnym na 100 osób w wieku produkcyjnym - 2024
x53 - x55	odsetek ludności w wieku produkcyjnym - 2021 sp	Współczynnik obciążenia demograficznego (liczba osób w wieku nieprodukcyjnym na 100 osób w wieku produkcyjnym - 2024
x06 - x14	saldo migracji stałej w % rok do roku - 2024	jednostki nowo zarejestrowane w rejestrze REGON w roku 2024 na 10 tys. Ludności
x02 - x51	wskaźnik urbanizacji 2021 - spis powszechny - ile osób % mieszka w miastach	zasoby mieszkaniowe gmin komunalne 2024 na 10,000 mieszkańców
x11 - x15	pkb na osobę w 2023 w 1000 zł	Przeciętne miesięczne wynagrodzenie brutto w 2024 w setkach zł
x15 - x54	Przeciętne miesięczne wynagrodzenie brutto w 2024 w setkach zł	odsetek ludności z wykształceniem wyższym. 2021 sp
x13 - x15	dochody budżetów województw na 1 mieszkańca w roku 2024 w dziesiątkach złotych	Przeciętne miesięczne wynagrodzenie brutto w 2024 w setkach zł

LABEL	OPIS CECHY 1	OPIS CECHY 2
x06 - x12	saldo migracji stałej w % rok do roku - 2024	podmioty wpisane do rejestru REGON na 1 tys. Ludności – 2024
x18 - x31	kilometry dróg publicznych ogółem na 100 km ² - 2024	wydatki budżetów gmin i miast na prawach powiatu na Ochrona powietrza atmosferycznego i klimatu na 1 mieszkańca w 2024 w setkach zł
x38 - x39	Lekarze pracujący bezpośrednio z pacjentem według województw w przeliczeniu na 10 tys. Mieszkańców – stan w dniu 31 grudnia 2023	Lekarze dentyści pracujący bezpośrednio z pacjentem według województw – na 10 tys Mieszkańców – stan 31 grudnia 2023
x01 - x19	gęstość zaludnienie (os / km2) - 2021 SP	kilometry dróg publicznych o nawierzchni twardej na 100 km ² - 2024
x13 - x28	dochody budżetów województw na 1 mieszkańca w roku 2024 w dziesiątkach złotych	WYDATKI BUDŻETÓW GMIN I MIAST NA PRAWACH POWIATU na 1 mieszkańca w 2024 w setkach zł
x11 - x28	pkb na osobę w 2023 w 1000 zł	WYDATKI BUDŻETÓW GMIN I MIAST NA PRAWACH POWIATU na 1 mieszkańca w 2024 w setkach zł
x12 - x13	podmioty wpisane do rejestru REGON na 1 tys. Ludności – 2024	dochody budżetów województw na 1 mieszkańca w roku 2024 w dziesiątkach złotych
x15 - x28	Przeciętne miesięczne wynagrodzenie brutto w 2024 w setkach zł	WYDATKI BUDŻETÓW GMIN I MIAST NA PRAWACH POWIATU na 1 mieszkańca w 2024 w setkach zł
x13 - x54	dochody budżetów województw na 1 mieszkańca w roku 2024 w dziesiątkach złotych	odsetek ludności z wykształceniem wyższym. 2021 sp
x14 - x22	jednostki nowo zarejestrowane w rejestrze REGON w roku 2024 na 10 tys. Ludności	przewozy pasażerskie na 1 mieszkańca 2024

Analiza najsilniejszych współczynników korelacji liniowej pozwala na zidentyfikowanie oczywistych, silnych sprzężeń strukturalnych w badanych województwach. Na

szczególną uwagę zasługują potężne, dodatnie korelacje wewnątrz bloku gospodarczo-inwestycyjnego (np. relacje między PKB (x_{11}), dochodami budżetów (x_{13}), nakładami inwestycyjnymi (x_{27}) oraz wynagrodzeniami (x_{15})), co potwierdza istnienie silnego mechanizmu samonapędzającego się rozwoju bogatszych regionów. Z kolei jedyne w zestawieniu silne korelacje ujemne (bliskie -0.92) dotyczą relacji zasobów ludzkich: im wyższy odsetek ludności w wieku produkcyjnym (x_{53}), tym mniejsze obciążenie demograficzne regionu (x_{55} i x_{56}), co logicznie odzwierciedla procesy starzenia się społeczeństwa dotyczące konkretne województwa w nierównomiernym stopniu.

Analiza kanoniczna

Podczas wstępnej analizy macierzy korelacji dostrzeżono wyraźne powiązania między badanymi cechami. Szczególną uwagę zwrócono na silne współzależności występujące pomiędzy dwoma konkretnymi podzespołami zmiennych. Pierwszy z nich, oznaczony jako zbiór X (zmienne od x_{11} do x_{15}), reprezentuje kondycję gospodarczą regionów. Drugi, oznaczony jako zbiór Y (zmienne od x_{27} do x_{30}), skupia się wokół szeroko rozumianych inwestycji.

Odkrycie tak wysokich współzależności między wskaźnikami gospodarczymi a inwestycyjnymi stało się impulsem do głębszego zbadania struktury tych powiązań. W tym celu postanowiono wykorzystać analizę korelacji kanonicznej (CCA). Narzędzie to pozwala sprawdzić, jak całe grupy zmiennych wpływają na siebie nawzajem.


W kontekście badanego dualizmu rozwoju regionalnego, wysoki wynik tej analizy wskazywałby na istnienie silnego mechanizmu: wyższy poziom gospodarczy, wyrażony m.in. przez PKB na mieszkańca, gęstość zarejestrowanych firm czy przeciętne wynagrodzenia, idzie w parze z lepszą jakością wskaźników inwestycyjnych, takich jak ogólne wydatki budżetowe gmin czy celowe nakłady na kulturę i oświatę. Dokładną strukturę oraz opisy cech, które zakwalifikowano do tego etapu badania, przedstawiono poniżej w Tabeli 1.

GOSPODARKA	x_{11}	pkb na osobę w 2023 w 1000 zł
GOSPODARKA	x_{12}	podmioty wpisane do rejestru REGON na 1 tys. Ludności – 2024
GOSPODARKA	x_{13}	dochody budżetów województw na 1 mieszkańca w roku 2024 w dziesiątkach złotych]
GOSPODARKA	x_{14}	jednostki nowo zarejestrowane w rejestrze REGON w roku 2024 na 10 tys. Ludności
GOSPODARKA	x_{15}	Przeciętne miesięczne wynagrodzenia brutto w 2024 w setkach zł

INWESTYCJE	x_{27}	nakłady inwestycyjne w przedsiębiorstwach na 1 mieszkańca w 2024 w setkach zł
INWESTYCJE	x_{28}	WYDATKI BUDŻETÓW GMIN I MIAST NA PRAWACH POWIATU na 1 mieszkańca w 2024 w setkach zł
INWESTYCJE	x_{29}	Wydatki budżetów gmin i miast na prawach powiatu na kulturę i ochronę dziedzictwa narodowego na 1 mieszkańca w 2024 w dziesiątkach złotych
INWESTYCJE	x_{30}	Wydatki budżetów gmin i miast na prawach powiatu na oświatę 1 mieszkańca w 2024 w setkach zł

Analiza siły związków liniowych

Przed przystąpieniem do procedury korelacji kanonicznej, zweryfikowano strukturę powiązań liniowych wewnątrz oraz pomiędzy zbiorami X i Y . Na Rysunku 2.1 przedstawiono zestawienie macierzy korelacji dla wszystkich analizowanych kombinacji cech.



Rysunek 2.8 Wszystkie kombinacje korelacji między zmiennymi kanonicznymi X , Y

- **Korelacje wewnątrz podsystemu Gospodarki (Zbiór X)**

Wszystkie cechy z tej grupy (x_{11} – x_{15}) wykazują bardzo silną współzależność, a wskaźniki korelacji przekraczają próg 0.80. Oznacza to, że wysokie PKB, liczba prowadzonych firm per capita oraz wysokie zarobki mocno idą ze sobą w parze i wspólnie budują jeden silny wymiar definiujący gospodarkę.

- **Korelacje wewnątrz podsystemu Inwestycji (Zbiór Y)**


W tej grupie korelacje są wysokie, ale z wyraźnymi wyjątkami dla wydatków na kulturę (x_{29}). Para nakłady inwestycyjne firm (x_{27}) a wydatki na kulturę (x_{29}) cechuje się tylko umiarkowaną korelacją (0.41) – czyli inwestycje przedsiębiorstw

idą z kulturą w parze tylko częściowo. Z kolei para wydatki na kulturę (x_{29}) a wydatki na oświatę (x_{30}) ma słabą korelację (0.18), co oznacza, że wydatki na te dwa obszary społeczne nie są ze sobą bezpośrednio powiązane.

- **Korelacje krzyżowe (Gospodarka X vs Inwestycje Y)**

W przypadku porównania obu zbiorów ze sobą, niemal wszystkie cechy charakteryzują silne relacje powyżej 0.50. Wyjątkiem są ponownie wydatki na kulturę (x_{29}). Pokazują one słabszy związek z PKB na osobę (x_{11} : 0.44) oraz z dochodami budżetów województw (x_{13} : 0.47).


Analizę dopełnia Rysunek 2.2, który przedstawia wykresy rozrzutu wzbogacone o czerwoną linię trendu. Widać na nich, że wzrost jednej cechy w uogólnieniu oznacza automatyczny wzrost drugiej. Ciekawym zjawiskiem jest jednak to, że na niemal każdym wykresie występuje ta sama wartość nietypowa, punkt reprezentujący województwo mazowieckie. Mimo przeskalowania cech na wskaźniki gęstości, czyli na osobę, na 100 osób czy na kilometr kwadratowy, mazowieckie nadal drastycznie odbiega w górę od reszty kraju. Jest to w pełni zrozumiałe, ponieważ w Warszawie realizuje się najwięcej inwestycji, a duża część wydatków na kulturę i oświatę skupia się w stolicy, gdzie zlokalizowane są najlepsze szkoły, uczelnie oraz kluczowe wydarzenia kulturalne w Polsce.



Rysunek 2.9 Wykres rozrzutu między kombinacjami wybranych zmiennych

Interpretacja korelacji i ładunków kanonicznych

Po zapoznaniu się ze specyfiką analizowanych cech, zrealizowano algorytm analizy korelacji kanonicznej. Procedura ta polega na wyznaczeniu zmiennych kanonicznych poprzez takie dobranie wag dla poszczególnych cech, aby uzyskana korelacja między podsystemami była jak najwyższa. Na Rysunku 2.3 przedstawiono rezultaty tego procesu w postaci ładunków kanonicznych, które obrazują siłę powiązań między oryginalnymi zmiennymi a ich własnymi wymiarami, jak również ich korelacje ze zmienną kanoniczną przeciwnego podsystemu.



Rysunek 2.10 Graf przedstawiający korelację między cechami, a zmiennymi kanonicznymi

W wyniku przeprowadzonej procedury statystycznej uzyskano ekstremalnie wysoki współczynnik pierwszej korelacji kanonicznej, który wyniósł 0.973. Tak wysoka wartość, bliska jedności, świadczy o niemal idealnej, dodatniej współzależności liniowej między sferą gospodarczą a inwestycyjną w badanych województwach.

W praktyce oznacza to, że zmiany w poziomie rozwoju gospodarczego regionów są nierozzerwalnie sprzężone z ich potencjałem inwestycyjnym. Województwa charakteryzujące się silną gospodarką generują wyższe nakłady inwestycyjne, zarówno te twarde w przedsiębiorstwach, jak i społeczne, realizowane przez samorządy.

Analiza wartości ładunków kanonicznych oraz korelacji krzyżowych prowadzi do wniosku, że wybrane do badania zmienne diagnostyczne charakteryzują się bardzo wysoką stabilnością merytoryczną. W niemal każdym analizowanym przypadku poszczególne cechy wykazują potężne powiązanie zarówno ze swoim własnym teoretycznym wymiarem, jak i z komponentem przeciwnego podsystemu.

Wyjątkiem od tej reguły są wydatki na kulturę (x_{29}). Cecha ta – zarówno w relacji z macierzystym wymiarem inwestycyjnym (0.509), jak i w korelacji krzyżowej z wymiarem gospodarczym (0.496), osiąga wyraźnie niższe wskaźniki korelacji, oscylujące wokół granicy 0.50. Choć wartość ta wciąż mieści się w przedziale zależności umiarkowanych i potwierdza udział kultury w ogólnym rozwoju regionu, to wyraźny dystans wobec pozostałych zmiennych niesie ważną informację strukturalną. Finansowanie kultury w polskich województwach wykazuje pewną autonomię, nie jest ono aż tak bezpośrednio i sztywno zdeterminowane ogólną kondycją gospodarczą czy pozostałym potencjałem inwestycyjnym samorządów, jak ma to miejsce w przypadku twardej infrastruktury czy szkolnictwa.

Testy istotności statystycznej

Oprócz merytorycznej interpretacji ładunków i współczynników korelacji kanonicznej, kluczowym etapem analizy było zweryfikowanie, czy uzyskane wyniki niosą ze sobą istotną informację statystyczną, czy są jedynie dziełem losowego zbiegu okoliczności. W tym celu przeprowadzono wielowymiarowe testy istotności ogólnej: test Wilksa, Pillai'a, Hotellinga oraz najszerzego pierwiastka Roya. W Tabeli 2.1 przedstawiono wyniki wielowymiarowych testów istotności dla całego układu zmiennych kanonicznych

Tabela 2.1 Wyniki testów statystycznych

Wilks Lambda	Hotelling-Lawley Trace	Pillai-Bartlett Trace	Roy's Largest Root
0.0163	0.0002	0.2176	0.0000

Prezentowane w Tabeli 2.1 wyniki testów jednoznacznie potwierdzają obecność silnych, nieprzypadkowych zależności pomiędzy analizowanymi podsystemami danych. Wartości prawdopodobieństwa testowego (p -value) dla statystyk Wilksa (0,0163), Hotellinga-Lawleya (0,0002) oraz Roya (0,0000) ukształtowały się poniżej rygorystycznego progu istotności $\alpha = 0,05$. Pozwala to na bezpieczne odrzucenie hipotezy zerowej o braku powiązań i przyjęcie, że wyizolowane zmienne kanoniczne niosą ze sobą kluczową informację statystyczną. Odmienny rezultat testu Pillai'a ($p = 0,2176$), będącego najbardziej konserwatywną z procedur, nie podważa ogólnej wiarygodności modelu, ponieważ dominująca większość statystyk jednoznacznie sankcjonuje poprawność oraz wysoką stabilność zbudowanego układu relacji.

Analiza redundancji

W celu pełniejszej oceny relacji zachodzących między badanym potencjałem gospodarczym a sferą inwestycyjną, analizę korelacji kanonicznych pogłębiono o badanie wskaźników redundancji. Pozwoliło to na jednoznaczne zweryfikowanie, w jakim stopniu nowo wygenerowane wymiary teoretyczne posiadają realną zdolność predykcyjną i potrafią wyjaśnić zmienność surowych wskaźników wejściowych z przeciwnego podsystemu danych.

Tabela 2.2 Współczynniki redundancji

Współczynnik redundancji (Xcan1)	Współczynnik redundancji (Ycan1)
0.7877	0.6196

Uzyskane współczynniki redundancji kanonicznej dla pierwszego wymiaru stanowią silne empiryczne potwierdzenie głębokich, współzależnych relacji pomiędzy badanymi obszarami. Wskaźnik Xcan1 na poziomie 0,7877 dowodzi, że pierwsza zmienna kanoniczna sfery inwestycyjnej (Y) jest w stanie wyjaśnić aż 78,77% całkowitej wariancji surowych cech gospodarczych (x_{11} – x_{15}). W relacji zwrotnej, współczynnik Ycan1 równy 0,6196 wskazuje, że wyizolowany konstrukt sfery gospodarczej (X) determinuje 61,96% zmienności wskaźników inwestycyjnych (x_{27} – x_{30}). Tak wysoka dwukierunkowa zdolność predykcyjna modelu dostarcza twardych dowodów na istnienie silnego sprzężenia zwrotnego pomiędzy potencjałem ekonomicznym regionów a ich aktywnością inwestycyjną. W kontekście analizy dualizmu struktur, synchroniczne reagowanie obu grup wskaźników oraz wysoki stopień transferu informacji między nimi jednoznacznie potwierdzają teoretyczne założenia o nierozdzielnej, systemowej zależności obu podsystemów w przekroju regionalnym.

Analiza głównych składowych

Celem analizy głównych składowych (algorytm PCA) w kontekście omawianego zbioru danych jest redukcja jak największej ilości zmiennych poprzez przekształcenie zbioru w taki sposób, by zmaksymalizować wartość informacyjną każdego z wymiarów. Operacja ta polega na tym, że po wystandaryzowaniu zmiennych tworzony jest nowy układ współrzędnych, na który punkty są rzutowane w taki sposób, aby ich wariancja była jak największa. Dzięki takiemu przekształceniu możliwe jest zawarcie większej liczby informacji reprezentowanych przez pierwotne zmienne przy użyciu mniejszej liczby nowych zmiennych.


Wybór zmiennych do analizy

Algorytm PCA jest niezwykle pomocną metodą, jednak wprowadzanie do niego wszystkich dostępnych zmiennych, których w prezentowanej analizie jest ponad 50, mogłoby zaburzyć wyniki z powodu szumu informacyjnego. Z tego względu w pierwszej kolejności wyeliminowano zmienne, których współczynnik zmienności był niższy niż 0.25, ponieważ nie różnicowały one w wystarczającym stopniu badanego zbioru. W analizie zdecydowano się na rygorystyczne kryterium 0,25 zamiast powszechnie stosowanego w literaturze progu 0,1. Decyzja ta wynikała z dużej liczby zmiennych oraz z chęci wyselekcjonowania jedynie tych cech, które silnie różnicują województwa, co pozwoli na wyraźniejsze uwypuklenie zachodzącego między nimi dualizmu. Drugim kryterium doboru cech była analiza ich wzajemnej korelacji, gdzie przedział decyzyjny współczynnika korelacji Pearsona ustalono na [0,7; 0,9]. Górny próg (0,9) zastosowano w celu wyeliminowania zmiennych współliniowych, które niosą niemal identyczną wartość informacyjną. Z kolei dolny próg (0,7) pozwolił na odrzucenie cech zbyt słabo powiązanych z pozostałymi.


Na Rysunku 3.1 przedstawiono macierz korelacji przed eliminacją cech, która wyraźnie obrazuje potrzebę wstępnej selekcji zmiennych. Bez tego zabiegu algorytm PCA oparty na ponad 50 cechach byłby nieefektywny, ponieważ duże rozproszenie informacji wymusiłoby stworzenie wielu wymiarów (PC_i) do wyjaśnienia wariancji, co zaprzecza idei redukcji. Dodatkowo silna współliniowość wprowadzałaby szum informacyjny, sztucznie zniekształcając obraz dysproporcji między regionami.

Rysunek 3.2 prezentuje strukturę danych po zredukowaniu zbioru do zaledwie 16 kluczowych zmiennych. Dzięki temu drastycznie wzrasta szansa na to, że cała esencja informacji zostanie zawarta w mniejszej liczbie wymiarów, co ułatwi późniejszą interpretację. Usunięcie szumu pozwoliło wyodrębnić silną strukturę powiązań oraz dychotomiczny charakter relacji.

Rysunek 3.11 Macierz korelacji przed redukcją cech



Rysunek 3.12 Macierz korelacji oraz częściowej korelacji po eliminacji cech



Poniżej przedstawiono zestaw zmiennych, które spełniły kryteria formalne i zostały zakwalifikowane do analizy składowych głównych.

DEMOGRAFIA	x01	gęstość zaludnienie (os / km ²) - 2021 SP
DEMOGRAFIA	x03	emigranci - 2021 sp - odsetek emigrantów w % względem ludności województwa - czasowy pobyt za granica
EDUKACJA	x09	studencki uczelni na 1,000 ludności - 2024
GOSPODARKA	x13	dochody budżetów województw na 1 mieszkańca w roku 2024 w dziesiątkach złotych]
INSRASTRUKTURA TRANSPORTOWA	x17	drogi dla rowerów na 1,000 km ² 2024
INSRASTRUKTURA TRANSPORTOWA	x18	kilometry dróg publicznych ogółem na 100 km ² - 2024
INSRASTRUKTURA TRANSPORTOWA	x19	kilometry dróg publicznych o nawierzchni twardej na 100 km ² - 2024
INSRASTRUKTURA TRANSPORTOWA	x20	(przystanki autobusowe (z trolejbusowymi) i tramwajowe, przystanki wspólne dla tramwajów i autobusów) na 100km ² w 2024
INSRASTRUKTURA TRANSPORTOWA	x21	długość linii komunikacji miejskiej na 100,000 mieszkańców 2024 w km
INSRASTRUKTURA TRANSPORTOWA	x22	przewozy pasażerskie na 1 mieszkańca 2024
INSRASTRUKTURA TRANSPORTOWA	x24	linie kolejowe ogółem na 1000 km ² w 2024
INWESTYCJE	x31	wydatki budżetów gmin i miast na prawach powiatu na Ochrona powietrza atmosferycznego i klimatu na 1 mieszkańca w 2024
STAN MATERIALNY	x43	Stopa promil bezrobocia w grudniu 2024
STAN MATERIALNY	x44	BENEFICJENCI ŚRODOWISKOWEJ POMOCY SPOŁECZNEJ w promilach
WARUNKI BYTOWE	x49	liczba miejsc w domach studenckich w stosunku do liczby studentów 2024 - jaki odsetek studentów domy studenckie są w stanie pomieścić
WARUNKI BYTOWE	x50	studenci korzystający z domów studenckich w % ogółu studentów 2024

Wyselekcjonowany zestaw 16 zmiennych diagnostycznych charakteryzuje się wysoką wszechstronnością, łącząc kluczowe aspekty demograficzne, gospodarcze oraz infrastrukturalne, co pozwala na wielowymiarową ocenę i syntetyczną redukcję stopnia rozwoju badanych jednostek regionalnych za pomocą algorytmu PCA.


Wyniki działania algorytmu PCA

Po wykonaniu algorytmu PCA otrzymano rezultat widoczny w tabeli 3.1.

Tabela 3.8 Wyniki prezentujące, w jak dużym stopniu dany wymiar wyjaśnia oryginalne dane

Wymiar	Wartość własna (Eigenvalue)	Procent wariancji (%)	Skumulowany % wariancji
Dim.1	7.84	48.97	48.97
Dim.2	2.73	17.07	66.04
Dim.3	1.92	12.00	78.04
Dim.4	1.35	8.42	86.46
Dim.5	0.61	3.79	90.25
Dim.6	0.47	2.96	93.21
Dim.7	0.33	2.08	95.29
Dim.8	0.26	1.65	96.94
Dim.9	0.19	1.17	98.11
Dim.10	0.12	0.76	98.87
Dim.11	0.10	0.62	99.49
Dim.12	0.04	0.27	99.76
Dim.13	0.03	0.18	99.94
Dim.14	0.01	0.06	100.00
Dim.15	0.00	0.00	100.00
Dim.16	0.00	0.00	100.00

Przeprowadzona analiza składowych głównych wykazała silną redukowalność przestrzeni cech. Pierwsze cztery główne składowe kumulują łącznie 86,46% całkowitej wariancji zawartej w pierwotnym zbiorze 16 zmiennych. Dodatkowo potwierdza to rysunek 3.3 przedstawiający korelację między nowo stworzonymi wymiarami PCA, a oryginalnymi danymi.



Rysunek 3.13 Macierz korelacji między oryginalnymi danymi, a wymiarami PCA

Oprócz samej redukcji liczby cech, szczegółowej analizie poddano ładunki czynnikowe budujące poszczególne składowe, co pozwoliło na merytoryczną interpretację wyodrębnionych wymiarów. W analizie statystycznej przyjmuje się, że zmienne o ładunkach powyżej 0.5 (co do wartości bezwzględnej) mają kluczowy wpływ na kształt danej składowej. Pierwsza składowa główna (PC1) skupia w sobie największy budżet informacji i wykazuje ekstremalnie silne korelacje z większością zmiennych bazowych. Ze względu na silne, ujemne powiązanie z gęstością zaludnienia oraz infrastrukturą drogową, przy jednoczesnym dodatnim skorelowaniu z poziomem bezrobocia i pomocy społecznej, składowej PC1 przypisano właściwość ogólnego poziomu urbanizacji oraz rozwoju strukturalno-gospodarczego regionu.

Z kolei druga składowa główna (PC2) charakteryzuje się ogólnie niższymi ładunkami w skali całego zbioru, jednak wyraźnie przejawia dominującą rolę informacyjną w obszarach, które miały mniejsze znaczenie dla PC1. Najwyższe współczynniki korelacji dla PC2 odnotowano dla zmiennych x09, x13, x20 oraz x22, które reprezentują odpowiednio: liczbę studentów na 1000 ludności, dochody budżetowe jednostek, gęstość infrastruktury przystankowej oraz wielkość przewozów pasażerskich. Na tej podstawie można wnioskować, że wymiar PC2 identyfikuje podaspekt struktury regionalnej, który można określić jako potencjał akademicko-gospodarczy oraz stopień rozwoju mobilności miejskiej.

Wybór wymiarów

W celu wyznaczenia optymalnej liczby składowych głównych, które powinny zostać zatrzymane w modelu, przeanalizowano kilka alternatywnych podejść badawczych. Każde z nich charakteryzuje się odmiennymi zaletami oraz ograniczeniami.


Najpowszechniej stosowaną procedurą jest metoda osypiska (tzw. metoda łokcia), polegająca na wizualnej ocenie wykresu i wskazaniu punktu, w którym następuje najsilniejsze załamanie krzywej wartości własnych. Główną wadą tego podejścia jest jego wysoka subiektywność, ponieważ różni analitycy mogą odmiennie interpretować ten sam wykres. Na przykładzie badanych danych tzw. łokieć można zaobserwować zarówno już przy składowej PC2, jak i dopiero przy PC5. Wizualny wybór oscyluje zatem w szerokim przedziale od dwóch do pięciu wymiarów, co uniemożliwia podjęcie jednoznacznej decyzji.

Kolejnym podejściem jest tradycyjne kryterium Kaisera, które zakłada zatrzymanie wyłącznie tych składowych, których wartość własna (eigenvalue) przekracza 1. Zaletą tej metody jest jej prostota oraz wysoka skuteczność w standardowych zbiorach danych. Słabą stroną kryterium Kaisera jest jednak jego wrażliwość na szum informacyjny. Jeśli dane wejściowe będą wykazywały wysoki stopień losowej zmienności lub będą zawierały zmienne słabo skorelowane, kryterium to może błędnie wskazać konieczność zatrzymania większej liczby wymiarów, niż jest to merytorycznie uzasadnione. Na rysunku 4 przedstawiono wartości własne kolejnych wymiarów, gdzie granica kryterium Kaisera została oznaczona czerwoną, poziomą linią przerywaną.


Najbardziej efektywną i odporną na szum losowy metodą okazała się analiza równoległa Horna. Istota tej procedury polega na generowaniu przy użyciu symulacji Monte Carlo N-krotnych, sztucznych zbiorów danych wypełnionych liczbami całkowicie losowymi, dla których następnie oblicza się teoretyczne wartości własne. Pozwala to na precyzyjne odcięcie składowych reprezentujących wyłącznie przypadkowy szum. Na rysunku 5 zaprezentowano wyniki analizy Horna w dwóch wariantach: opartym na wartości średniej dla każdego wymiaru oraz na wartości 95. percentyla. Wariant wykorzystujący 95. percentyl jest bardziej restrykcyjny, ponieważ wymaga, aby rzeczywista wartość własna była wyższa od aż 95% wyników wygenerowanych czysto losowo, co minimalizuje ryzyko zakwalifikowania do modelu składowych niemających realnego uzasadnienia empirycznego.

Poniżej przedstawiam wyniki każdego z podejść w formie tabelarycznej.

Metoda osypiska	Kryterium Kaisera	Analiza Horna (Średnia)	Analiza Horna (95 percentyl)
2 lub 5	4	1	1



Rysunek 3.14 Wykres przedstawiający kolejne wartości własne oraz kryterium Kaisera $\lambda > 1$



Rysunek 3.15 Wykres przedstawiający wyniki wszystkich analiz wyboru wymiarów PCA

Analiza uzyskanych rezultatów prowadzi do niejednoznacznych wniosków, co wymaga od analityka podjęcia kompromisowej decyzji merytorycznej. Zgodnie z rygorystycznymi wskazaniami analizy równoległej Horna (zarówno dla kryterium średniej, jak i 95. percentyla), jedynym statystycznie istotnym wymiarem jest pierwsza składowa główna (PC1). Wynik ten koresponduje z układem ładunków czynnikowych, gdzie większość oryginalnych zmiennych wykazuje silną korelację ($|r| > 0.5$) właśnie z pierwszym wymiarem.

Z kolei tradycyjne kryterium Kaisera sugeruje zatrzymanie aż czterech składowych głównych, które łącznie wyjaśniają wysoką, wynoszącą aż 86,46% część całkowitej wariancji. Wizualizacja korelacji na mapie ciepła wskazuje jednak, że składowe trzecia (PC3) i czwarta (PC4) wiążą się już tylko z pojedynczymi, bardzo wąskimi cechami bazy noclegowej akademików, co w kontekście ogólnej analizy rozwoju regionów może stanowić modelowanie szumu informacyjnego.

Mając na uwadze powyższe rozbieżności, podjęto decyzję o zatrzymaniu dwóch pierwszych składowych głównych (PC1 i PC2). Samodzielna składowa PC1 wyjaśnia niecałe 50% wariancji (48,97). Włączenie do modelu składowej PC2 pozwala na dookreślenie kluczowego wymiaru gospodarczo-transportowego oraz studenckiego, którego pierwsza składowa nie była w stanie w pełni odzwierciedlić. Łączny zasób wyjaśnianej wariancji dla dwóch składowych wynosi 66,04. Za takim wyborem przemawia również fakt, że na wykresie analizy równoległej rzeczywista wartość własna dla drugiej składowej znajduje się bezpośrednio pod linią danych losowych, będąc niezwykle blisko granicy istotności statystycznej.

Metody porządkowania liniowego oraz nieliniowego

Wybór zmiennych do analizy

Dane wejściowe do przeprowadzenia analizy zawierały 56 zmiennych objaśniających dla 16 województw. Aby uzyskać optymalne cechy zastosowaliśmy dwie procedury:

- Filtr zmienności - Wyfiltrowaliśmy zmienne, dla których współczynnik zmienności wynosił $\leq 25\%$. W związku z powyższym liczba zmiennych została zredukowana z 56 do 25.
- Filtr współliniowości – Tutaj wyfiltrowaliśmy zmienne, które niosły tę samą lub bardzo podobną informację. W tym celu policzyliśmy korelację Pearsona dla każdej z par zmiennych. W przypadku par, dla których korelacja była większa niż 0.7 usunęliśmy zmienną o niższej unikalności informacyjnej. W ten sposób zredukowaliśmy liczbę zmiennych z 25 do 11.

Zmienne, które pozostały wybrane do analizy:

- X01 – Gęstość zaludnienia w osobach na km²
- X03 – Odsetek emigrantów z czasowym pobytem za granicą
- X09 – Studenci uczelni na 1,000 ludności
- X16 -Liczba rowerów publicznych na 100,000 ludności
- X23 – Linia regularnej komunikacji autobusowej w kilometrach na 100km²
- X26 – Wypadki drogowe na 100,000 ludności
- X36 – Zajęcia prowadzone przez centra kultury na 10,000 ludności
- X37 – Uczestnicy imprez organizowanych przez centra kultury na 1,000 ludności
- X45 – Miejsca noclegowe na 1,000 ludności
- X51 – Zasoby mieszkaniowe gmin na 10,000 ludności


Charakter zmiennych

- Destymulanty: X03 – odsetek imigrantów oraz x26 – liczba wypadków drogowych
- Stymulanty: Pozostałe 9 cech opisujących gęstość zaludnienia, infrastrukturę transportową i rowerową, zasoby akademickie oraz ofertę kulturalną i mieszkaniową

Przypisaliśmy zmiennym równe wagi, czyli $1/11 \sim 0.09$

Metoda COPRAS

Metoda ta opiera się na proporcjonalnej ocenie stopni bezpośredniej i odwrotnej zależności cech. Wyznaczyliśmy sumy ważonych stymulantów i destymulantów. Stopień użyteczności przyjmuje wartości z przedziału 0-100%, gdzie wartość 100% jest przypisywana „najlepszymu” województwu, a kolejne otrzymują proporcjonalnie słabszą punktację. Mazowieckie w metodzie COPRAS zajęło pierwsze miejsce z wynikiem 100%, i to właśnie ono jest „punktem odniesienia” dla innych województw w tej metodzie.



Rysunek 4.1 Ranking metody COPRAS

Rysunek 4.1 Wykres przedstawiający wyniki województw w klasyfikacji metodą COPRAS

Ważona metoda Hellwiga

Dane wejściowe poddaliśmy standaryzacji za pomocą funkcji `scale()` w R.

Zbudowaliśmy „wzorzec” podając wartości maksymalne z województw dla stymulant i wartości minimalne dla destymulant.


Obliczyliśmy ważoną odległość euklidesową dla każdego województwa od wzorca oraz miarę Hellwiga. Im miara Hellwiga bliższa 1, tym bardziej województwo jest zbliżone do „województwa idealnego”. W naszym przypadku najlepszym województwem jest zachodniopomorskie z wynikiem 0.33, a „najgorszym” warmińsko-mazurskie z wynikiem 0.07.

Ranking

Na podstawie miernika Hellwiga, kryterium średniej i odchylenia standardowego, podzieliliśmy województwa na 4 klasy.

Średnia = 0.1793

Odchylenie standardowe = 0.0886



Rysunek 4.2 Ranking metody ważonego Hellwiga

Rysunek 4.2 Wykres przedstawiający wyniki województw w metodzie Hellwiga ważonego

Grupa I – Bardzo wysoki poziom rozwoju

$H \geq 0.2679$

Województwa zachodniopomorskie, pomorskie oraz mazowieckie.

Grupa II – Wysoki poziom rozwoju

H w przedziale 0.1793-0.2679

Województwa **dolnośląskie, małopolskie** oraz **kujawsko-pomorskie**

Grupa III – Przeciętny poziom rozwoju


H w przedziale 0.0907-0.1793

Województwa **lubuskie, podlaskie, łódzkie, świętokrzyskie, lubelskie** oraz **wielkopolskie**

Grupa IV – Niski poziom rozwoju

$H < 0.0907$

Ranking kończą województwa **podkarpackie, opolskie** oraz **warmińsko-mazurskie**.




Rysunek 4.3 Wykres przesunięć rankingów

Rysunek 4.3 Wykres przedstawiający różnice w rankingach między metodą ważonego Hellwiga a metodą COPRAS

Jak widzimy na powyższym wykresie, województwo mazowieckie powędrowało z miejsca 3 w metodzie Hellwiga na miejsce 1 w metodzie COPRAS, ale województwa zachodniopomorskie oraz pomorskie solidnie spadły w rankingu. Zauważamy też, że znaczna część województw z grupy III poprawiła swój ranking i to dosyć znacząco, poza województwem łódzkim. Za to województwa z grupy IV również zajmują ostatnie miejsca.

Graf najbliższego sąsiada

Dwuwymiarowa płaszczyzna z nałożonym grafem najbliższego sąsiada. Łączy on każdy obiekt z najbliższym położonym obiektem względem odległości euklidesowej.



Rysunek 4.4 Graf porządkowania nieliniowego

Rysunek 4.4 Wykres przedstawiający wyniki województw wg grafu najbliższego sąsiada

Najbliżej sąsiadują ze sobą świętokrzyskie i lubelskie, co ma pokrycie w poprzednich analizach. Województwa te w wielu statystykach otrzymały podobne wyniki.

Na wykresie widzimy, że województwa takie jak mazowieckie, śląskie i zachodniopomorskie znajdują się z dala od innych województw, co oznacza, że cechy tych województw dosyć znacząco odbiegają wartościami od pozostałych.

Podsumowanie

Przeprowadzone analizy pozwoliły na zweryfikowanie hipotezy o nadal trwającym podziale na Polskę A oraz Polskę B, czyli rejon dobrze rozwinięty i słabiej rozwinięty. Wyjściowa baza 56 zmiennych po redukcji różnymi filtrami pozwoliła odpowiedzieć na to pytanie.

Zastosowanie metody COPRAS oraz ważonej metody Hellwiga wskazało na następujące wnioski

Województwo mazowieckie okazało się punktem odniesienia w metodzie COPRAS. Wynika to najpewniej z faktu, że w województwie mazowieckim znajduje się stolica Polski, Warszawa. Jest to oczywiście gospodarcze centrum Polski i najważniejszy ośrodek gospodarczy kraju.

Wg metody Hellwiga województwo zachodniopomorskie okazało się liderem z wynikiem 0.33. Wraz z województwami pomorskim i mazowieckim zaklasyfikowały się do czołówki, Grupy I, czyli rejonów z bardzo wysokim poziomem rozwoju. Na drugim biegunie widzimy województwa podkarpackie, opolskie oraz warmińsko-mazurskie z wynikiem 0.07


Wyniki te pokazały, że województwa wschodnie, takie jak warmińsko-mazurskie, podlaskie, lubuskie i podkarpackie, faktycznie wynikami odbiegają od pozostałych województw. Możemy więc potwierdzić, że podział na Polskę A i B nadal jest widoczny.

Analiza skupień

Metoda Warda

Metoda Warda jest przydatna, gdy dążymy do zminimalizowania wariancji wewnątrz jednego skupienia obiektów. Wyniki metody na dendrogramie poniżej:

STRUKTURA PODZIAŁU HIERARCHICZNEGO (METODA WARDA)



Rysunek 5.1 Dendrogram przedstawiający podział hierarchiczny województw metodą Warda

Tutaj również możemy zauważyć, że warmińsko-mazurskie oraz lubuskie łączą się ze sobą bardzo szybko, w odległości ok. 2.

Jak widzimy na dendrogramie, województwa zostały podzielone na 3 wyraźne „bloki”.

- Mazowieckie, łódzkie, dolnośląskie, pomorskie, małopolskie, śląskie
- Podkarpackie, podlaskie, kujawsko-pomorskie, opolskie, wielkopolskie, lubelskie, świętokrzyskie
- Zachodniopomorskie, lubuskie, warmińsko-mazurskie

Co ciekawe, województwo zachodniopomorskie zostało zaklasyfikowane do grupy, w której możemy znaleźć „mniej rozwinięte” województwa, mimo że zachodniopomorskie w poprzednich rankingach było w top 3 województw względem rozwoju. Być może wiele cech w województwie zachodniopomorskim jest podobnych do województw mniej rozwiniętych.

Metoda k-średnich

Metoda k-średnich polega na iteracyjnym podziale zbioru danych na z góry określoną liczbę k rozłącznych klas. Algorytm rozpoczyna działanie od losowego lub heurystycznego wyznaczenia początkowych środków ciężkości dla każdej grupy. W kolejnych krokach każdy obiekt z analizowanego zbioru zostaje przypisany do najbliższego centroidu, najczęściej na podstawie metryki odległości euklidesowej. Po przypisaniu wszystkich obiektów następuje ponowne przeliczenie pozycji centroidów jako średniej współrzędnych punktów wchodzących w skład danej klasy. Proces ten jest powtarzany aż do momentu stabilizacji położenia centroidów lub osiągnięcia limitu iteracji. Dążeniem algorytmu jest minimalizacja wariancji wewnątrz powstałych grup.

W celu zmierzenia najlepszej liczby klas zastosowano wskaźnik Silhouette, który ocenia jakość grupowania poprzez analizę stopnia dopasowania każdego obiektu do jego własnej klasy w porównaniu z klasą sąsiednią. Dla każdego punktu oblicza się różnicę między średnią odległością do innych punktów z tej samej grupy a średnią odległością do punktów z najbliższej, obcej grupy. Wskaźnik ten przyjmuje wartości z przedziału $[-1,1]$, gdzie wartości bliskie 1 oznaczają, że obiekty są poprawnie przypisane, a poszczególne skupienia są od siebie wyraźnie odseparowane.

Kolejnym użytym narzędziem była metoda łokcia, polegająca na analizie wykresu sumy kwadratów błędów wewnątrzklasowych w funkcji rosnącej liczby skupień k . Wraz ze wzrostem liczby klas wartość SSE naturalnie maleje, jednak od pewnego momentu ten spadek gwałtownie zwalnia. Optymalną liczbę skupień wyznacza punkt załamania wykresu, przypominający zgięty łokieć, za którym dalsze komplikowanie modelu nie przynosi już istotnej poprawy jakości podziału.


W analizie wykorzystano również indeks Daviesa-Bouldina, który różni się od wskaźnika Silhouette przede wszystkim tym, że jest miarą dążącą do minimalizacji, a nie maksymalizacji, oraz opiera się na bezpośrednim stosunku rozproszenia wewnątrzklasowego do odległości między centroidami grup. Podczas gdy Silhouette ocenia każdy obiekt indywidualnie i szuka wartości jak najbliższej 1, indeks Daviesa-Bouldina ocenia globalną relację między parami klas – im niższa wartość tego indeksu,

tym lepsze grupowanie, ponieważ oznacza to, że klasy są wewnętrznie bardzo spójne (skupione), a jednocześnie szeroko od siebie odseparowane.

Na rysunkach 5.2-5.4 przedstawiono proponowane podziały.

ANALIZA OPTYMALNEJ LICZBY KLAS


Rekomendacja: $k = 2$ (najwyższa spójność klas)



Rysunek 5.2 Proponowana liczba klas na podstawie wskaźnika Silhouette

METODA ŁOKCIA (ELBOW METHOD)


Szukamy momentu załamania krzywej (punktu przegięcia)



Rysunek 5.3 Proponowana liczba klas na podstawie metody łokcia

ANALIZA OPTYMALNEJ LICZBY KLAS

Rekomendacja: $k = 3$ (pierwszy wyraźny spadek DBI)




Rysunek 5.4 Proponowana liczba klas na podstawie indeksu Daviesa-Bouldina

Przedstawiona analiza wielokryterialna wskazuje jednoznacznie na optymalną liczbę skupień $k=3$. Mimo że wskaźnik Silhouette sugeruje najwyższą spójność dla dwóch klas to metoda łokcia i indeks Daviesa-Bouldina wskazują na $k=3$. Ostatecznie wybrano podział na 3 klasy ponieważ zapewnia on najlepszą separację grup przy jednoczesnym zachowaniu spójności, co optymalizuje proces dalszej analizy danych.

JAKOŚĆ WYODRĘBNIONYCH KLAS

Średnia jakość podziału = 0.22



Rysunek 5.5 Zestawienie wskaźników Silhouette dla poszczególnych województw

Analiza wskaźnika Silhouette dla poszczególnych województw potwierdza zróżnicowaną jakość przypisania obiektów do wyodrębnionych trzech klas przy średniej wartości podziału wynoszącej 0.22. Najwyższy poziom spójności i poprawne zakwalifikowanie odnotowano dla województwa lubelskiego, warmińsko-mazurskiego oraz pomorskiego. Wyrażą anomalią jest województwo małopolskie, które uzyskało ujemny wynik na poziomie minus 0.14, co oznacza, że wykazuje większe podobieństwo do sąsiedniej grupy niż do tej, do której zostało pierwotnie przypisane.

Na rysunku 5.6 przedstawiono proponowany podział województw na trzy klasy. Najmniej liczną grupę stanowi Klasa 2, która skupia specyficzny region południowy Polski, czyli województwa śląskie i małopolskie. Obszar ten charakteryzuje się unikalnymi cechami społeczno-gospodarczymi, gdzie wysoka gęstość zaludnienia oraz silne tradycje przemysłowe Śląska płynnie łączą się z dynamicznie rozwijającą się gospodarką opartą na usługach biznesowych, innowacjach, nauce oraz turystyce w Małopolsce. Z kolei Klasa 3 zrzesza regiony o najwyższym stopniu zamożności i silnej pozycji rynkowej, wyznaczonej przez dynamiczne ośrodki wojewódzkie o zasięgu ogólnokrajowym i międzynarodowym. Pozostała część kraju utworzyła najliczniejszą Klasę 1, reprezentującą regiony o bardziej tradycyjnej i stabilnej strukturze ekonomicznej.

KLASYFIKACJA WOJEWÓDZTW

Przynależność terytorialna do wyodrębnionych klas

Klasa 1	Klasa 2	Klasa 3
KUJAWSKO-POMORSKIE	MAŁOPOLSKIE	DOLNOŚLĄSKIE
LUBELSKIE	ŚLĄSKIE	MAZOWIECKIE
LUBUSKIE		POMORSKIE
OPOLSKIE		ŁÓDZKIE
PODKARPACKIE		
PODLASKIE		
WARMIŃSKO-MAZURSKIE		
WIELKOPOLSKIE		
ZACHODNIOPOMORSKIE		
ŚWIĘTOKRZYSKIE		

Rysunek 16.6 Proponowany podział województw na klasy metodą k-średnich


Metoda Fuzzy c-średnich

Fuzzy C-Means to algorytm klasteryzacji rozmytej, który w przeciwieństwie do klasycznego K-means pozwala na to, aby jeden punkt danych należał do kilku grup jednocześnie z różnym stopniem przynależności. Aby ocenić jakość takiego podziału bez sztucznego "wyostrzania" wyników, stosuje się wskaźnik rozmytej sylwetki, który mierzy, jak dobrze punkty pasują do swoich grup przy jednoczesnym uwzględnieniu ich wielogrupowej natury. Na rysunku 5.7 przedstawiono porównanie wartości średniej wskaźnika sylwetki rozmytej. Według algorytmu, najlepszy podział zostanie osiągnięty dla czterech klas. Na rysunku 5.8 przedstawiono stopień przynależności każdego województwa do danej klasy okazały się bardzo nieliczne i rozmyte, przez co algorytm przypisał im większość punktów z minimalnym, niemal losowym stopniem przynależności. Istnieje ryzyko, że to szum informacyjny i sztucznie zaniżona wartość wskaźnika Fuzzy Silhouette. Z drugiej strony, patrząc na rysunek 5.11, podział wydaje się dość sensowny. Klasa 2 reprezentuje Śląsk, czyli region bardzo specyficzny pod względem gospodarki i infrastruktury, natomiast Klasa 3 (stolice) skupia obszary najbogatsze. Interesująca jest Klasa 4, obejmująca województwa lubelskie i warmińsko-mazurskie, jednak taki układ może mieć uzasadnienie, ponieważ oba te regiony

charakteryzują się niższym poziomem PKB per capita oraz dominacją sektora rolniczego, co strukturalnie zbliża je do siebie na tle reszty kraju.

ANALIZA OPTYMALNEJ LICZBY KLAS (FUZZY SILHOUETTE)


Rekomendacja: $k = 4$ (najwyższa spójność rozmyta)



Rysunek 5.7 Proponowana liczba klas na podstawie wskaźnika Fuzzy Silhouette

STRUKTURA PRZYNALEŻNOŚCI WOJEWÓDZTW


Model rozmyty Fuzzy C-Means ($k = 4$)



Rysunek 5.8 Struktura przynależności województw

JAKOŚĆ WYODRĘBNIONYCH KLAS

Globalna rozmyta sylwetka FS = 0.326



Rysunek 5.9 Zestawienie wskaźników Fuzzy Silhouette dla poszczególnych województw

KLASYFIKACJA ROZMYTA WOJEWÓDZTW

Stopień przynależności do wyodrębnionych grup ($k = 4$) - Dane surowe

Województwo	Klasa 1	Klasa 2	Klasa 3	Klasa 4	Klasa Dominująca
KUJAWSKO-POMORSKIE	0.778	0.012	0.154	0.056	Klasa 1
LUBELSKIE	0.483	0.022	0.177	0.318	Klasa 1
OPOLSKIE	0.748	0.021	0.138	0.093	Klasa 1
PODKARPACKIE	0.707	0.017	0.149	0.127	Klasa 1
PODLASKIE	0.457	0.026	0.301	0.216	Klasa 1
ŚWIĘTOKRZYSKIE	0.873	0.005	0.076	0.046	Klasa 1
WIELKOPOLSKIE	0.785	0.014	0.125	0.076	Klasa 1
ŚLĄSKIE	0.001	0.997	0.002	0.001	Klasa 2
DOLNOŚLĄSKIE	0.060	0.008	0.907	0.025	Klasa 3
ŁÓDZKIE	0.344	0.039	0.532	0.085	Klasa 3
MAŁOPOLSKIE	0.254	0.190	0.304	0.252	Klasa 3
MAZOWIECKIE	0.257	0.043	0.596	0.105	Klasa 3
POMORSKIE	0.185	0.074	0.621	0.120	Klasa 3
ZACHODNIOPOMORSKIE	0.302	0.038	0.355	0.304	Klasa 3
LUBUSKIE	0.038	0.006	0.031	0.925	Klasa 4
WARMIŃSKO-MAZURSKIE	0.074	0.011	0.049	0.866	Klasa 4

Rysunek 5.10 Klasyfikacja rozmyta województw

KLASYFIKACJA WOJEWÓDZTW (FUZZY C-MEANS)

Przynależność terytorialna do grup na podstawie dominującego stopnia przynależności

Klasa 1	Klasa 2	Klasa 3	Klasa 4
KUJAWSKO-POMORSKIE	ŚLĄSKIE	DOLNOŚLĄSKIE	LUBUSKIE
LUBELSKIE		MAZOWIECKIE	WARMIŃSKO-MAZURSKIE
OPOLSKIE		MAŁOPOLSKIE	
PODKARPACKIE		POMORSKIE	
PODLASKIE		ZACHODNIOPOMORSKIE	
WIELKOPOLSKIE		ŁÓDZKIE	
ŚWIĘTOKRZYSKIE			

Rysunek 5.11 Proponowany podział województw na klasy metodą Fuzzy c-średnich

Podsumowanie

W grafie najbliższego sąsiada widzimy, że mazowieckie, śląskie i zachodniopomorskie odbiegają wartościami od pozostałych.

Większość wskaźników wykazała, że najlepiej podzielić Polskę na trzy główne grupy, a uzyskany podział okazał się bardzo spójny. Pierwszą, największą klasę tworzą regiony rolnicze i turystyczne, do których zostało przydzielone również bogatsze finansowo województwo zachodniopomorskie. Drugą grupę stanowi specyficzny, przemysłowo-usługowy region śląsko-małopolski, a trzecią najbogatsze województwa z wielkimi aglomeracjami, takimi jak Mazowsze czy Dolny Śląsk. Co ciekawe, z analizy wskaźnika Silhouette wyszła anomalia dla Małopolski – algorytm połączył ją ze Śląskiem, ale jej statystyki pokazują, że tak naprawdę bardziej pasuje do najbogatszych metropolii.

Analiza rozmyta pokazuje, że większość regionów ma stabilną pozycję i należy do jednej klasy. Z kolei województwa takie jak lubelskie, podlaskie czy zachodniopomorskie mają cechy mieszane i mocno balansują pomiędzy różnymi grupami. Na tym tle wyróżniają się śląskie, lubuskie i dolnośląskie o skrajnie wyrazistym profilu, podczas gdy Małopolska jest najbardziej "rozmytym" regionem, łączącym w sobie cechy aż trzech klas jednocześnie.

Podsumowanie

Biorąc pod uwagę przeprowadzone analizy, można dojść do wniosku, że w kontekście zgromadzonych danych podział Polski na część A i B jest silnie uzależniony od badanych zmiennych oraz metodologicznego kontekstu.

W ramach analizy wstępnej dysponowaliśmy dużym zbiorem danych. Ocena statystyk asymetrii i skośności wykazała, że w przypadku większości wskaźników rozkłady były względnie symetryczne, a przejścia między poziomami rozwoju województw były płynne. Wyraźną anomalię stanowiły jednak pojedyncze województwa dominujące w konkretnych obszarach, gdzie asymetria prawostronna ujawniła pozycję Mazowsza jako lidera gospodarczego oraz Śląska jako bieguna infrastrukturalnego.

W analizie kanonicznej wyselekcjonowane zmienne stworzyły silnie powiązane bloki w macierzy korelacji. Pozwoliło to na postawienie i pozytywne zweryfikowanie hipotezy, czy nakłady gospodarcze idą w parze z nakładami inwestycyjnymi. Okazało się, że wyższy poziom rozwinięcia ekonomicznego regionu determinuje wyższą aktywność inwestycyjną. Jedynym istotnym wyjątkiem okazały się wydatki na kulturę i ochronę dziedzictwa narodowego, które wykazują umiarkowaną niezależność i nie są tak sztywno sprzężone ze wskaźnikami makroekonomicznymi jak twarda infrastruktura czy oświata.

Przystępując do analizy głównych składowych, postawiliśmy przed sobą dwa cele, czyli redukcję wymiarowości silnie skorelowanych cech dotyczących głównie transportu, edukacji, ochrony zdrowia oraz stanu materialnego, a także identyfikację nowo powstałych struktur ukrytych. Choć zastosowane algorytmy pozwoliły na redukcję blisko 70% informacji pierwotnej, formalne kryteria wyboru liczby składowych były rozbieżne, ponieważ analiza równoległa Horna sugerowała jeden wymiar, a kryterium Kaisera aż cztery. Podjęliśmy kompromisową decyzję o zatrzymaniu dwóch pierwszych składowych, ponieważ pierwsza z nich wyjaśniała niecałe 50% wariancji, a włączenie drugiej pozwoliło na precyzyjniejsze ujęcie komponentu akademicko-transportowego.

Kolejnym krokiem było zastosowanie metod porządkowania liniowego, takich jak COPRAS i ważona metoda Hellwiga, w celu stworzenia syntetycznego rankingu województw. Porównanie obu procedur wykazało, że wyniki były wysoce zbieżne w dolnych rejestrach zestawienia, wskazując stałą grupę regionów o niższym poziomie rozwoju. Istotne różnice pojawiły się natomiast w czołówce rankingu. Oznacza to, że identyfikacja województw peryferyjnych jest stabilna niezależnie od metody, podczas gdy pozycja liderów pozostaje silnie wrażliwa na matematyczną konstrukcję samego miernika syntetycznego.

Ostatnim etapem było grupowanie jednostek z wykorzystaniem analizy skupień metodą Warda, k-średnich oraz Fuzzy c-średnich. Niezależnie od wybranego algorytmu, podział wyraźnie odseparował województwa z silnymi i silnie zurbanizowanymi ośrodkami

aglomeracyjnymi, które są uznawane powszechnie za lepiej rozwinięte, od regionów o charakterze bardziej tradycyjnym, rolniczo-turystycznym.

Podsumowując, dychotomiczna klasyfikacja kraju na Polskę A i B w ujęciu holistycznym nie jest zagadnieniem jednoznacznym. Chęć zbadania tak szerokiego spektrum zależności w ramach jednej pracy była decyzją odważną, jednak wielowymiarowa natura danych statystycznych rzadko pozwala na zero-jedynkowe odpowiedzi. Z perspektywy czasu mądrzejszym podejściem mogłoby okazać się zawężenie tematyki lub przeprowadzenie kilku niezależnych i węższych analiz, a dopiero w kolejnym kroku dokonanie ich merytorycznej syntezy. Niemniej jednak, projekt udowodnił, że wielowymiarowe metody taksonomiczne odzwierciedlają rzeczywiste dysproporcje regionalne, a uzyskane wyniki statystyczne w dużej mierze pokrywają się z powszechną intuicją społeczno-gospodarczą.

Bibliografia

Literatura

- Dr. Mathias Jesussek, Dr. Hannah Volk-Jesussek. *Statistics made easy: A clear and simple introduction (8th edition)*. Numiqo. 2026
- Andrzej Bąk. *Porządkowanie liniowe obiektów metodą Hellwiga i TOPSIS–analiza porównawcza*. Prace Naukowe Uniwersytetu Ekonomicznego we Wrocławiu, (426), 22-31. 2016
- Paweł Churski, Robert Perdał, Barbara Konecka-Szydłowska, Tomasz Herodowicz. *Redefinicja czynników rozwoju regionalnego w świetle megatrendów społeczno-gospodarczych*. Studia Regionalne i Lokalne, 3 (73), 70-98. 2018
- Wojciech Dziemianowicz, Jan Goliński, Jacek Szlachta. *Dualizm ekonomiczny i megatrendy – Przyczynek do dyskusji o rozwoju terytorialnym*. Prace i Studia Geograficzne, 67(1), 75-92. 2022

Materiały wideo

- Numiqo. *Principal Component Analysis (PCA) Explained Simply*. online: https://www.youtube.com/watch?v=_6UjscCJrYE&t=5s, [dostęp: 04.05.2026]
- StatQuest with Josh Starmer. *StatQuest: Principal Component Analysis (PCA), Step-by-Step*. online: <https://www.youtube.com/watch?v=FgakZw6K1QQ&t=525s>, [dostęp: 04.05.2026]
- TileStats. *Canonical correlation analysis – explained*. online: <https://www.youtube.com/watch?v=2tUuyWTtPqM>. [dostęp: 15.05.2026]
- StatQuest with Josh Starmer. *StatQuest: K-means clustering*. online: <https://www.youtube.com/watch?v=4b5d3muPQmA&t=385s>. [dostęp: 29.05.2025]